ZORLU HAVA KOŞULLARINDA TRAFİK VE YOL NESNELERİ ALGILAMA İLE ADAPTİF KARAR VERME SİSTEMİ

İÇİNDEKİLER

Sayfa No:

İÇİNDEKİLER……..II

ÖZET VI

ŞEKİLLER DİZİNİ VII

TABLOLAR DİZİNİ.....VII

SEMBOLLER DİZİNİ VIII

DENKLEMLER DİZİNİ……..……...….IX

1. GİRİŞ…….11

1.1. Genel Bilgiler…….11

1.1.2 Konunun Seçilme Nedeni……..…….12

1.1.3 Konunun Günümüzde Kullanım Alanları……..……12

1.2. Literatür Araştırması……...……..12

1.3. Özgünlük……13

1.3.1 Çok Katmanlı Sensör Fizyonu ile Risk Skorlama…….….13

1.3.2 Zaman Paylaşımlı (Time - Sliced) Gerçek Zamanlı İşleme…….……..13

1.3.3 Çok Kriterli ve Hiyerarşik Karar Mekanizması……..…..13-14

1.3.4 Hıza Bağlı Adaptif Şerit Takip…….…..14

1.4. Yaygın Etki…….……...…14

1.5. Standartlar……14-18

1.6. Çalışma Takvimi……...…18-22

2. TEORİK ALTYAPI…….…..22

2.1. Genel Bilgiler…….22

2.2. Görüntü İyileştirme ve Nesne Tespiti…….22

2.2.1. Nesne Tespiti - YOLO..... 22

2.2.2. Görüntü İyileştirme - DehazeFormer…….22

2.3. Lider Veri İşleme ve Mesafe Analizi…….23

2.3.1 Nokta Bulutu Filtreleme…….23

2.3.2 Mesafe ve TTC Hesaplaması…….23
2.4. Risk Hesaplama ve Karar Verme……...23
2.4.1. Risk Skoru……23-24
2.5. Araç Kontrol Sistemleri…….24
2.5.1. PID Hız Kontrolü……...24
2.5.2. Direksiyon Kontrolü - Waypoint Takibi ve CTE Düzeltmesi……25
2.6. Trafik Işığı Algılama - Fusion……25
3. TASARIM……..25
3.1. Genel Bilgiler……..…..…25-26
3.2. Sistem Bileşenleri ve Seçimleri……..26
3.2.1. CARLA Simülasyon Ortamı……..26
3.2.2. RGB Kamera Sensörü……26
3.2.3. LiDAR Sensörü……..26
3.2.4. YOLO Nesne Tespit Modeli…….26-27
3.2.5. DehazeFormer Görüntü İyileştirme Modeli……...27
3.2.6. PID Kontrol Sistemi……...27
3.3. Uygulanan Yöntemle……..27
3.3.1. Sensör Veri Akışı ve Senkronizasyon……27
3.3.2. Görüntü İyileştirme……...27-28
3.3.3. Nesne Algılama ve Sonrası Filtreleme……...28
3.3.4. LiDAR Veri İşleme ve TTC Hesaplama……28
3.3.5. Risk Skoru Hesaplama……..28-29
3.3.6. Adaptif Karar Mekanizması……...29
3.3.7. Araç Kontrolü……..29
3.3.8. Trafik Işığı Algılama……...29
3.3.9. Validasyon ve Telemetri…….30
3.4. Yazılımlar……30
3.4.1. Genel Yazılım Mimarisi……..30
3.4.2. Yazılım Modülleri……..…30-31
3.4.3. Algoritmik Yapı ve İş Akışı…….…..31
3.4.4. Direksiyon Kontrolü ve Şerit Takibi…….…….31

3.4.5. Sözde Kod (Pseudo Code)…….....31-33
3.4.6. Akış Diyagramı Açıklaması…….…….34-38
3.5. Malzeme Listesi ve Ekonomik Analiz……...39
4. SİMÜLASYON (BENZETİM) ÇALIŞMALARI…….39
4.1. Genel Bilgiler……39-40
4.2. Simülasyon Yazılımı……..40
4.2.1. CARLA Simülatörü……40
4.2.2. Sensör Yapılandırması……...……40
4.2.3. Hava Koşulları ve Sis Modellemesi……...41
4.3. Sistem Modelleme……..41
4.3.1. Ego Araç Modeli……41
4.3.2. Çevre ve Trafik Modellemesi…….41
4.3.3. Validasyon Modeli……41-42
5. DENEYSEL ÇALIŞMALAR……...42
5.1. Genel Bilgiler……42
5.2. Yazılım ve Donanım Ekipmanlarının Birleştirilmesi……..42-43
5.3. Arayüz Elemanlarının Gerçeklenmesi……..43
5.4. Yapılan Testler……43-44
6. SONUÇLAR…….……45
6.1. Genel Açıklamalar…….……...45
6.2. Simülasyon Sonuçları…….……..45
6.2.1. Nesne Algılama Modeli Eğitim Sonuçları…….…….45-47
6.2.2. Sis Giderme Modülü Performans Sonuçları…….…….……47
6.2.3. Simülasyon Ortamında Tespit Doğruluğu Sonuçları…….…….....47-50
6.2.4. Validasyon ve Karşılaştırmalı Performans Sonuçları…….……50-52
6.3. Deney Sonuçları……52
6.3.1. Sistem Çalışma Zamanı Analizi…….……..52-53
6.3.2. Validasyon Metrikleri Özeti…….……53
6.3.3. Sensör Füzyonunun Etkisi…….……53
7. DEĞERLENDİRMELER…….53
7.1. Çalışmanın Kazanımları……...53-55

7.2. Sınırlılıklar, Zorluklar ve Eleştirel Değerlendirme……..55-56
7.3. Gelecek Çalışmalar……..56-57
8. KAYNAKLAR……... 58-6

ÖZET

Otonom sürüş sistemlerinin güvenilirliği, sis, yağmur ve düşük ışık gibi zorlu hava koşullarında önemli ölçüde düşmektedir. Bu çalışmada, kamera ve LiDAR sensör verilerini birleştiren (sensör füzyonu), sisli hava koşullarında görüntü kalitesini derin öğrenme tabanlı yöntemle iyileştiren ve risk skoru tabanlı adaptif karar mekanizması içeren bütünleşik bir otonom sürüş sistemi geliştirilmiştir. Sistem, CARLA açık kaynak simülasyon ortamında gerçek zamanlı olarak test edilmiştir.

Görüntü iyileştirme katmanında DehazeFormer-S modeli kullanılarak sis etkisi azaltılmış, kontrast artırımı için gamma düzeltme, CLAHE ve unsharp masking adımları uygulanmıştır. Nesne algılama katmanında YOLOv11 modeli, Roboflow platformunda hazırlanan 7 sınıflı (person, vehicle, signal, pothole, speedbump, obstacle, animal) ve 20.000 görüntülük veri seti üzerinde fine-tuning ile eğitilmiştir. LiDAR veri işleme katmanında nokta bulutu filtreleme, üstel hareketli ortalama (EMA) ile gürültü bastırma ve Time-To-Collision (TTC) hesaplaması gerçekleştirilmiştir.

Risk analizi katmanında LiDAR mesafesi, TTC, YOLO tabanlı nesne sınıfı ve trafik ışığı durumu birleştirilerek ağırlıklı çok boyutlu bir risk skoru üretilmiştir. Karar verme katmanında emergency > tl_stop > hard_brake > soft_brake > slow > caution > go hiyerarşisi ile çok kriterli ve öncelik tabanlı mod geçişleri sağlanmıştır. Araç kontrol katmanında PID hız kontrolcüsü ile hedef hız takibi, waypoint tabanlı yön hatası ve Cross Track Error (CTE) düzeltmesi ile şerit merkezileme birleştirilmiştir.

Zaman paylaşımlı işleme yaklaşımı ile DehazeFormer her 2 karede bir, YOLO her karede çalıştırılarak hesaplama kaynakları verimli kullanılmış ve düşük gecikmeli gerçek zamanlı performans sağlanmıştır. Validasyon Manager modülü ile CARLA ground truth verisi karşılaştırılarak precision, recall ve F1-score metrikleri hesaplanmıştır. Simülasyon sonuçları, sis giderme öncesi %25.2 olan ortalama F1 skorunun, DehazeFormer sonrası %52.2'ye yükseldiğini göstermiştir. Özellikle vehicle sınıfında precision %35.8'den %88.2'ye, F1 skoru %27.8'den %65.5'e yükselmiştir. Sensör füzyonunun tek sensöre göre algılama robustluğunu artırdığı, hiyerarşik karar mekanizmasının karmaşık trafik senaryolarında güvenli mod geçişleri sağladığı doğrulanmıştır. Sistem, SAE J3016 kapsamında Seviye 5 otonom sürüş gereksinimlerine ve ISO 26262 fonksiyonel güvenlik standartlarına uygun olarak tasarlanmıştır.

Anahtar Kelimeler: Sensör Füzyonu, Görüntü İyileştirme**,** Adaptif Karar Verme

ŞEKİLLER DİZİNİ

Sayfa No:

Şekil 1. Çalışma sürecine ait iş paketleri ve zaman çizelgesi……..18
Şekil 2. Önerilen sistemin genel algoritmasına ait sözde kod (Kısım 1)…….32
Şekil 2. Önerilen sistemin genel algoritmasına ait sözde kod (Kısım 2)…….33
Şekil 3. Otonom sürüş sisteminin genel çalışma akış diyagramı (Kısım1)…….35
Şekil 3. Otonom sürüş sisteminin genel çalışma akış diyagramı (Kısım2)…….36
Şekil 3. Otonom sürüş sisteminin genel çalışma akış diyagramı (Kısım 3)…….37
Şekil 3. Otonom sürüş sisteminin genel çalışma akış diyagramı (Kısım 4)……38
Şekil 4. Nesne tespit modeli eğitim sürecine ait kayıp (loss) ve performans metrikleri grafikleri……..46
Şekil 5. Nesne tespit modeline ait normalize edilmiş karmaşıklık matrisi.....47
Şekil 6. Sisli orijinal görüntü ve sis giderme (DehazeFormer) modülü sonrası elde edilen görüntü karşılaştırması…….....47
Şekil 7. Simülasyon ortamında nesne tespiti ve risk skorlama sonuçlarını gösteren ekran görüntüsü.....48
Şekil 8. Sisli hava koşullarında YOLO modelinin nesne tespit sonuçları ve performans Metrikleri……....49
Şekil 9. Sis giderme sonrası nesne tespiti ve performans verileri……...50
Şekil 10. Sis giderme işlemi uygulanmadan önceki (ham sisli görüntüler) model performans metrikleri……..51
Şekil 11. Sisli ortamda eğitilmiş modelin nesne sınıflarına göre performans metrikleri.52

TABLOLAR DİZİNİ

Sayfa No:

Tablo 1. Geliştirilen otonom sürüş sisteminin temel bileşenleri, kullanılan yöntemler ve görevleri……11

Tablo 2. Çalışma kapsamında dikkate alınan uluslararası otonom sürüş ve güvenlik standartları……15-17

Tablo 3. Veri seti özellikleri ve yapılandırma bilgileri…….19

Tablo 4. Risk skoru bileşenleri, ağırlık katsayıları ve gerekçeleri…….21

Tablo 5. Mesafe ve TTC değerlerine göre belirlenen eşik değerleri…….24

SEMBOLLER DİZİNİ

Δt	: Zaman adımı (s)
TTC	: Time-To-Collision, çarpışma zamanı (s)
EMA	: Exponential Moving Average, üstel hareketli ortalama
α	: EMA filtreleme katsayısı
PID	: Proportional-Integral-Derivative kontrolcü
Kp	: Oransal kazanç
Ki	: Birikimsel kazanç
Kd	: Türevsel kazanç
CTE	: Cross Track Error, şerit sapması (m)
FOV	: Field of View, görüş açısı (°)
mAP	: mean Average Precision
HSV	: Hue-Saturation-Value renk uzayı
CLAHE	: Contrast Limited Adaptive Histogram Equalization
ADAS	: Advanced Driver Assistance Systems
ASIL	: Automotive Safety Integrity Level
YOLO	: You Only Look Once (nesne tespit algoritması)

DENKLEMLER DİZİNİ

Sayfa No:

Denklem (1) : Üstel hareketli ortalama (EMA) filtreleme formülü……..23
Denklem (2) : Time-To-Collision (TTC) hesaplama formülü……..23
Denklem (3) : Ağırlıklı risk skoru hesaplama formülü…….24
Denklem (4) : PID kontrol algoritması formülü……....24

1. GİRİŞ

1.1. Genel Bilgiler

Otonom sürüş sistemleri, çevresel algılama, karar verme ve kontrol mekanizmalarının bütünleşik çalışmasına dayanır. Bu sistemlerin güvenilirliği, özellikle sis, yağmur ve düşük ışık gibi zorlu hava koşullarında önemli ölçüde düşmektedir. Kamera tabanlı algılama sistemleri, atmosferik saçılma nedeniyle görüntü kontrastının azalması ve nesne sınırlarının belirsizleşmesi sonucu performans kaybı yaşar [4]. LiDAR sensörleri ise sis damlacıklarından kaynaklanan lazer ışını saçılması (Mie saçılması) nedeniyle nokta bulutunda gürültü artışı ve menzil azalması ile karşılaşır [1].

Bu çalışmada, kamera ve LiDAR sensör verilerini birleştiren (sensor fusion) [1], sisli hava koşullarında görüntü kalitesini derin öğrenme tabanlı yöntemle iyileştiren [12] ve risk skoru tabanlı adaptif karar mekanizması içeren bütünleşik bir otonom sürüş sistemi geliştirilmiştir. Sistem, CARLA [25] açık kaynak simülasyon ortamında gerçek zamanlı olarak test edilmiştir. Geliştirilen sistemin temel bileşenleri, kullanılan algoritmalar ve bu bileşenlerin üstlendiği görevler Tablo 1'de özetlenmiştir.

Tablo 1. Geliştirilen otonom sürüş sisteminin temel bileşenleri, kullanılan yöntemler ve görevleri

Bileşen	Yöntem	Görev
Görüntü İyileştirme	DehazeFormer (Transformer tabanlı)	Sis etkisini azaltma, kontrast artırma
Nesne Algılama	YOLOv11 (tek aşamalı detektör)	Araç, yaya, trafik ışığı, işaret tespiti
Mesafe Ölçümü	LiDAR nokta bulutu + EMA filtreleme	Çevresel derinlik haritası oluşturma
Risk Analizi	TTC + ağırlıklı skorlama	Çarpışma riski nicelendirme
Araç Kontrolü	PID hız kontrolü + Pure Pursuit/CTE direksiyon kontrolü	Kararlı sürüş davranış

1.1.2. Konunun Seçilme Nedeni

Bu konunun seçilme nedeni, mevcut otonom sürüş sistemlerinin zorlu hava koşullarındaki performans açığını kapatmaya yönelik bütünleşik çözümlere olan ihtiyaçtır. Özellikle sensör füzyonu ve görüntü iyileştirmenin bir arada değerlendirildiği sistemler literatürde sınırlıdır [3]. Günümüzdeki otonom sürüş çalışmaları genellikle ideal hava koşullarına odaklanmakta; sis, yağmur ve düşük ışık gibi gerçek dünya senaryolarında sistemlerin güvenilirliği önemli ölçüde düşmektedir. Bu nedenle, görüntü iyileştirme, çoklu sensör füzyonu ve adaptif karar mekanizmalarını tek bir çatı altında birleştiren bütünleşik bir yaklaşıma duyulan akademik ve endüstriyel ihtiyaç bu çalışmanın temel motivasyonunu oluşturmaktadır.

1.1.3. Konunun Günümüzde Kullanım Alanları

Günümüzde otonom sürüş teknolojileri; otomotiv sektörü, lojistik sistemleri, akıllı ulaşım altyapıları, sürücü destek sistemleri ve insansız taşıma platformları gibi birçok alanda kullanılmaktadır. Özellikle gelişmiş sürücü destek sistemlerinde (ADAS), araç çevresinin algılanması ve risk analizine dayalı karar mekanizmaları büyük önem taşımaktadır.

1.2. Literatür Araştırması

Görüntü İyileştirme Alanı: Xu vd. [4], düşük ışık koşullarında yapısal modelleme ve rehberli iyileştirme yöntemi önermiş, ancak sisli ortamlarda performans sınırlı kalmıştır. Wang vd. [5], Generative Adversarial Network (GAN) tabanlı düşük ışık görüntü iyileştirmesi gerçekleştirmiş, PSNR metriğinde %12'ye varan artış sağlamıştır. He vd. [6], SwinLightGAN ile transformer ve derinlik artıklarını birleştirerek düşük ışık senaryolarında başarım göstermiştir. Ancak bu çalışmalar ya düşük ışığa ya da sisli ortamlara özeldir; ikisini birleştiren çalışmalar nadiridir.

Nesne Algılama Alanı: YOLO ailesi (YOLOv5, v8, v11) otonom sürüşte yaygın kullanılan tek aşamalı detektörlerdir. Dang vd. [7], YOLOv5'i kötü hava koşullarında trafik işareti algılama için uyarlamıştır. Li vd. [8], DSF-YOLO ile çok ölçekli trafik işareti tespiti gerçekleştirmiş, ancak sadece işaret sınıfına odaklanmıştır. Aldoski ve Koren [9], YOLOv11'in farklı hava koşullarındaki performansını simülasyonda değerlendirmiştir.

Adaptif Karar Verme: Huang vd. [10], otonom araçlar için oyun teorisi tabanlı adaptif karar mekanizması önermiştir. Wang vd. [11], derin pekiştirmeli öğrenme ile hibrit

durum uzayı ve sürüş riski modellemiştir. Ancak bu çalışmalar görüntü iyileştirme ve nesne algılama ile entegre değildir.

Bu çalışmanın farkı: Literatürdeki çalışmalar genellikle tek bir alt probleme (ya görüntü iyileştirme, ya nesne algılama, ya karar verme) odaklanırken, bu tezde (1) DehazeFormer [12] ile sis giderme, (2) YOLO [26] ile çok sınıflı algılama, (3) LiDAR [2] ile mesafe ölçümü, (4) TTC [2] tabanlı risk skorlama ve (5) PID [3] kontrollü araç yönetimi tek bir mimaride birleştirilmiştir.

1.3. Özgünlük

Bu çalışmanın literatürden ve mevcut çözümlerden ayrılan temel özellikleri şunlardır:

1.3.1. Çok Katmanlı Sensör Füzyonu ile Risk Skorlama

Kamera (görsel algılama) ve LiDAR (derinlik algılama) verileri, ağırlıklı risk skoru hesaplamasında entegre edilmiştir. Literatürde genellikle tek sensör üzerine kurulu veya basit eşik değerli (threshold-based) karar sistemleri bulunurken, bu çalışmada LiDAR mesafesi, TTC (Time-To-Collision), YOLO tabanlı nesne sınıfı (yaya, araç, engel) ve trafik ışığı durumu birleştirilerek çok boyutlu bir risk metriği üretilmektedir. Ağırlık katsayıları ile farklı sensörlerin güvenilirlik düzeylerine göre adaptif birleştirme sağlanmıştır. Bu yapı, tek sensör sistemlerine göre daha robust (dayanıklı) bir algılama ve karar zinciri oluşturmaktadır.

1.3.2. Zaman Paylaşımlı (Time-Sliced) Gerçek Zamanlı İşleme

Sistem, CARLA senkron modunda $\Delta t=0.05s$ zaman adımıyla çalışmaktadır. İşlem yükünü dengelemek amacıyla görüntü iyileştirme (DehazeFormer) her 2 karede bir, nesne algılama (YOLO) ise her karede zaman paylaşımlı olarak yürütülmektedir. Bu yaklaşım, hesaplama kaynaklarını verimli kullanarak düşük gecikmeli (low-latency) gerçek zamanlı performans sağlamaktadır. İyileştirilmiş görüntüler bir sonraki karede YOLO girişi olarak kullanılmakta, böylece süreklilik korunmaktadır.

1.3.3. Çok Kriterli ve Hiyerarşik Karar Mekanizması

Sadece mesafe tabanlı değil; TTC, nesne sınıfı (yaya, araç, engel), trafik ışığı durumu ve risk skoru birlikte değerlendirilmektedir. Karar motoru (DecisionEngine), farklı senaryolar için öncelik sıralaması içeren hiyerarşik bir yapı kullanmaktadır: emergency > tl_stop > hard_brake > soft_brake > slow > caution > go. Örneğin, yaya algılaması araç

takibine göre, kırmızı ışık ise her ikisine göre üst önceliklidir. Bu sayede karmaşık trafik senaryolarında dinamik ve güvenli mod geçişleri sağlanmaktadır.

1.3.4. Hıza Bağlı Adaptif Şerit Takip

Şerit takip için waypoint tabanlı hedef nokta belirleme ile Cross Track Error (CTE) düzeltmesi birleştirilmiştir. İlerideki waypoint'lerin ağırlıklı ortalaması (%40 orta nokta, %60 son nokta) hedef olarak kullanılmakta, hıza bağlı dinamik ileri mesafe ayarı ile düşük hızlarda daha yakın, yüksek hızlarda daha uzun hedef noktalar seçilmektedir. CTE düzeltmesinde hıza bağlı kazanç ayarı ile düşük hızlarda agresif, yüksek hızlarda yumuşak şerit merkezileme elde edilmektedir. CTE düzeltme üst limiti ile aşırı salınım (overshoot) önlenmektedir.

1.4. Yaygın Etki

Güvenlik Etkisi: Geliştirilen sistem, sisli koşullarda görüş mesafesinin %40-60 azaldığı senaryolarda [1] kamera-LiDAR füzyonu ile algılama mesafesini artırarak reaksiyon süresini uzatmaktadır. TTC tabanlı erken uyarı mekanizması, çarpışma riskini saniyeler öncesinden nicelendirmektedir.

Ekonomik Etki: Simülasyon tabanlı geliştirme, fiziksel prototip maliyetlerini ortadan kaldırmaktadır. Sistem, mevcut ADAS (Advanced Driver Assistance Systems) sistemlerine yazılım modülü olarak entegre edilebilir.

Akademik Etki: Çalışma, görüntü iyileştirme, nesne algılama ve kontrol sistemlerinin bütünleşik değerlendirilmesi açısından literatüre katkı sağlamaktadır. Elde edilen sonuçlar bilgisayarlı görü ve otonom sistemler alanındaki dergilerde yayınlanabilir.

Standartlar ve Uygunluk: SAE J3016 (Otonom Sürüş Seviyeleri) kapsamında Seviye 5 (Tam Otonom) sistemlere uygun tasarım yapılmıştır. ISO 26262 (Fonksiyonel Güvenlik) kapsamında risk analizi ve fail-safe mekanizmaları (emergency brake, tl_stop) entegre edilmiştir.

1.5. Standartlar

Bu çalışmada, otonom sürüş sistemlerinin tasarımı, geliştirilmesi ve test edilmesi sürecinde aşağıdaki uluslararası standartlar göz önünde bulundurulmuştur. Sistem, bu standartların gereklilikleri doğrultusunda risk analizi, fonksiyonel güvenlik ve performans değerlendirmesi yapacak şekilde yapılandırılmıştır. Sistemin tasarımı ve test süreçlerinde

uyumluluk gösterilen temel uluslararası standartlar ve bu standartların çalışma kapsamındaki uygulama alanları Tablo 2'de sunulmuştur.

Tablo 2. Çalışma kapsamında dikkate alınan uluslararası otonom sürüş ve güvenlik standartları

Standart Numarası	**Standart Adı**	**Kapsam ve Uygulama Alanı**
SAE J3016_202104	Taxonomy and Definitions for Terms Related to Driving Automation Systems [17]	Otonom sürüş seviyelerinin tanımlanması (Seviye 0-5). Bu çalışmada geliştirilen sistem, SAE J3016 kapsamında Seviye 5 (Tam Otonom) kategorisine girmektedir. Sistem; algılama, karar verme ve kontrol mekanizmalarını insan müdahalesi olmadan gerçek zamanlı olarak yürütmekte, sisli hava koşulları dahil olmak üzere tüm çevresel senaryolarda tam otonom sürüş gerçekleştirebilmektedir. Simülasyon ortamında elde edilen bu sonuçlar, gelecekteki fiziksel prototip çalışmaları için temel teşkil etmektedir.
ISO 26262-1:2018	Road Vehicles — Functional Safety [18]	Yol araçları elektrik/elektronik

		sistemlerinin fonksiyonel güvenliği. Sistemdeki risk skorlama ve fail-safe mekanizmaları (emergency brake, tl_stop) bu standardın ASIL (Automotive Safety Integrity Level) kavramına uygun olarak yapılandırılmıştır.
ISO/PAS 21448:2019	Road Vehicles — Safety of the Intended Functionality (SOTIF) [19]	Amaçlanan işlevselliğin güvenliği. Sistemin sensör performans sınırlılıkları (sisli hava, düşük ışık) ve algoritma yetersizlikleri bu standardın kapsamında değerlendirilmiştir.
ISO/SAE 21434:2021	Road Vehicles — Cybersecurity Engineering [20]	Yol araçları siber güvenlik mühendisliği. CARLA simülasyon ortamında veri iletişimi ve sensör füzyonu süreçlerinde güvenlik önlemleri göz önünde bulundurulmuştur.
IEEE 2846-2022	Standard for Assumptions in Safety-Related Models for Automated Driving Systems [21]	Otonom sürüş sistemlerinde güvenlik modellerinin varsayımları. Sistemin risk analizi ve TTC hesaplamaları bu

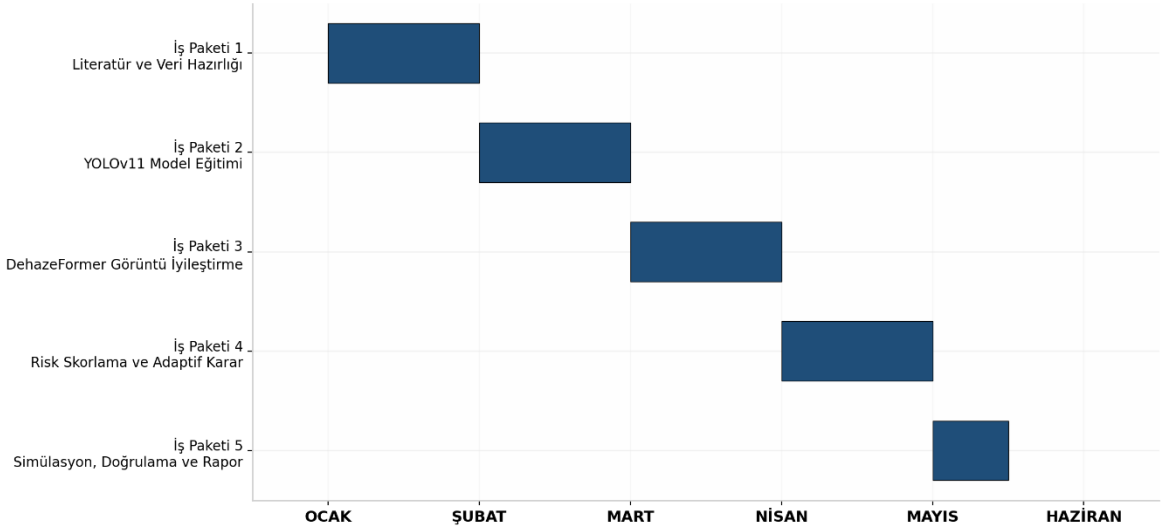
		standardın varsayım çerçevesine uygun olarak modellenmiştir.
IEEE 2857-2021	Standard for Assessing the Impact of Autonomous Vehicles on Road Traffic Safety [22]	Otonom araçların yol trafik güvenliğine etkisinin değerlendirilmesi. Sistemin validasyon metrikleri (precision, recall, F1-score) bu standardın değerlendirme çerçevesine paralel olarak yapılandırılmıştır.
UNECE R79	Uniform Provisions Concerning the Approval of Vehicles with Regard to Steering Equipment [23]	Direksiyon ekipmanları onay kuralları. Sistemin şerit takip ve direksiyon kontrol mekanizmaları bu düzenlemeye uygun olarak tasarlanmıştır.
UNECE R157	Uniform Provisions Concerning the Approval of Vehicles with Regard to Automatic Lane Keeping Systems (ALKS) [24]	Otomatik şerit koruma sistemleri. Sistemin CTE tabanlı şerit merkezileme ve yörünge takibi bu standardın ALKS gereksinimleri doğrultusunda optimize edilmiştir.

Bu standartlar, sistemin tasarım aşamasından simülasyon testlerine kadar olan süreçte referans alınmıştır. Özellikle SAE J3016 ve ISO 26262, sistemin otonom sürüş seviyesi belirlenmesi ve güvenlik kritik karar mekanizmalarının (acil fren, trafik ışığı durumu) tasarımında temel rehber olarak kullanılmıştır. SOTIF (ISO/PAS 21448) ise sisli hava

koşulları gibi performans sınırlılıklarının olduğu senaryolarda sistemin güvenli kalmasını sağlayacak ek önlemlerin alınmasını gerekli kılmıştır.

1.6. Çalışma Takvimi

Geri planlama yapıldığında, iş paketleri Ocak 2026'dan itibaren başlamalıdır. Aşağıdaki takvimde her iş paketi, bitiş tarihine kadar olan süreye göre optimize edilmiştir. Çalışmadaki iş paketleri ve bu işlerin ne kadar süreceği Şekil 1'de gösterilmiştir.



Şekil 1. Çalışma sürecine ait iş paketleri ve zaman çizelgesi

İş Paketi 1 — Literatür Taraması ve Roboflow Veri Seti Hazırlığı (06.01.2026 – 02.02.2026)

Veri Toplama ve Etiketleme:

Veri seti, Roboflow platformunda oluşturulmuş ve yönetilmiştir. Roboflow'un otomatik artırma (auto-augmentation) ve ön işleme pipeline'ı kullanılarak uygulanmıştır. Veri setine ait detaylar ve kullanılan parametreler Tablo 3'te gösterilmiştir.

Tablo 3. Veri seti özellikleri ve yapılandırma bilgileri

Parametre	Değer	Açıklama
Platform	Roboflow	Bulut tabanlı veri seti yönetimi ve etiketleme
Sınıf Sayısı	7	person, vehicle, signal, pothole, speedbump, obstacle, animal
Görüntü Sayısı	20.000	Özgün + artırılmış veri
Çözünürlük	640×640	YOLO giriş boyutu için otomatik yeniden boyutlandırma
Format	YOLOv11	Otomatik dönüşüm (PASCAL VOC → YOLO txt)
Artırma	Parlaklık, kontrast, gürültü, perspektif	Sisli/kötü hava koşullarını simüle etmek için

Veri Kaynakları:

Açık veri setleri: Açık veri setleri olarak kullanılan BDD100K[30], ACDC (Adverse Conditions Dataset), Animals, Pothole, More-SpeedBump, Debris, Road Debris ve Barrier veri setleri Roboflow platformu üzerinden temin edilmiştir. Özellikle ACDC veri setindeki sis, gece ve yağmur koşullarını içeren görüntüler ile trafik nesnelerinin bulunduğu alt kümeler seçilerek projeye uygun şekilde kullanılmıştır. Bu veri setleri, zorlu hava koşullarında nesne tespiti ve yol analizi çalışmalarında model eğitimi için kullanılmıştır.

CARLA [25] **sentetik veri:** Town10HD haritasında Python API ile üretilen senaryolar (farklı sis yoğunluğu: fog_density=15-60, farklı güneş açıları: sun_altitude_angle=15-75). Günde 500+ sentetik görüntü üretimi, Roboflow'a otomatik yükleme için script geliştirilmiştir.

Özel etiketleme: Roboflow Annotate arayüzünde bounding box ile manuel etiketleme, otomatik etiket önerisi (AI-assisted labeling) ile hızlandırılmıştır.

Roboflow Pipeline:

Ham Görüntüler → Yükleme (Roboflow Upload) → Etiketleme (Annotate)
→ Ön İşleme (Resize 640×640, Auto-Orient) → Artırma (Augmentation)

→ Versiyonlama (v1, v2, v3) → Export (YOLOv8 format, API key ile indirme)

B Planı: Roboflow API erişiminde kesinti olursa, veriler yerel olarak CVAT (Computer Vision Annotation Tool) ile etiketlenecek ve albumentations kütüphanesi ile artırma yapılacaktır.

İş Paketi 2 — YOLOv11 Nesne Algılama Modelinin Eğitimi (03.02.2026 – 23.02.2026)

YOLOv11 modeli, Roboflow'dan dataset.yml formatında indirilen veri seti üzerinde Google Colab ortamında 100 epoch ile eğitilmiştir. 7 sınıf (person, vehicle, signal, pothole, speedbump, obstacle, animal) için çok sınıflı nesne tespiti gerçekleştirilmiştir.

B Planı: YOLO eğitiminde düşük mAP değeri elde edilirse, Roboflow'da veri artırma parametreleri (döndürme açısı, parlaklık aralığı) genişletilecek veya EfficientDet-D0 alternatif modeli denenecektir.

İş Paketi 3 — DehazeFormer ile Görüntü İyileştirme (24.02.2026 – 30.03.2026)

Roboflow'dan indirilen veri seti, DehazeFormer-S modelinin fine-tuning'inde kullanılmıştır. Sisli görüntüler (fog_density > 20 olanlar) iyileştirme girişi olarak, aynı sahnenin sisiz hali (fog_density=0) ground truth olarak kullanılmıştır.

Model çıktısı sonrası pipeline: gamma düzeltme (γ=1.15) → CLAHE (clipLimit=1.5, tileGridSize=8×8) → unsharp masking → orijinal görüntü ile karıştırma (α=0.15, β=0.85).

B Planı: DehazeFormer [12] eğitiminde yakınsama sorunu yaşanırsa. DCP (Dark Channel Prior) [16] klasik yöntemi alternatif olarak devreye alınacaktır.

İş Paketi 4 — Risk Skorlama ve Adaptif Karar Mekanizması (31.03.2026 – 27.04.2026)

Risk skoru ağırlıklandırma ve PID parametreleri, YOLOv11 doğrulama sonuçlarına göre optimize edilmiştir. Sistemde kullanılan ağırlık katsayıları ve bu değerlerin seçilme nedenleri Tablo 4’te verilmiştir.

Tablo 4. Risk skoru bileşenleri, ağırlık katsayıları ve gerekçeleri

Bileşen	Ağırlık	Gerekçe
LiDAR mesafe	0.30	Doğrudan çarpışma olasılığı
TTC	0.20	Dinamik yaklaşma riski
YOLO-PERSON	0.35	Yaya güvenliği (en yüksek öncelik)
YOLO-VEHICLE	0.15	Araç takibi
Trafik ışığı	0.10	Kural tabanlı zorunluluk

Yüksek false positive oranı olan sınıflar (örneğin signal) için W_TRAFFIC_LIGHT ağırlığı dinamik olarak ayarlanmıştır.

B Planı: PID parametrelerinde osilasyon sorunu yaşanırsa, Ziegler-Nichols yöntemi ile sistematik ayar yapılacaktır.

İş Paketi 5 — Simülasyon Testleri, Doğrulama ve Raporlama (28.04.2026 – 15.05.2026)

Validation Manager modülü, CARLA'daki gerçek aktör pozisyonları ile YOLOv11 tespitlerini karşılaştırarak precision, recall ve F1-score hesaplar. Her 10 karede bir çalışır; trafik ışıkları 60 metre, diğer nesneler 45 metre mesafede kontrol edilir.

Test Edilen Senaryolar:

Şerit Takibi: Yoğun siste DehazeFormer şerit çizgilerini belirginleştirir. PID kontrolcü hedef hızı stabil tutar, CTE düzeltmesi virajlarda şerit merkezinde kalınmasını sağlar.

Ön Araç Takibi: LiDAR mesafesi 15 metre olduğunda sistem dikkat moduna geçer, TTC 3.5 saniyenin altına düştüğünde yumuşak frenleme yapar. YOLOv11 araç tespiti LiDAR'ı destekler.

Yaya Önceliği: Merkez bölgede yaya tespitinde risk skoru yükselir, emergency moduna geçilir. LiDAR mesafesi 4.2 metre, TTC 0.8 saniyede araç tamamen durur.

Trafik Işığı: CARLA API kırmızı bildirdiğinde durulur. YOLO fusion geçiş dönemlerini yakalayarak muhafazakar davranır, ışıktan 2.5 metre önce güvenli duruş sağlanır.

Telemetry kayıtları düşük ortalama risk skoru ve sınırlı acil fren sayısı ile proaktif risk yönetimini doğrular. Validasyon raporu Matplotlib ile her sınıf için precision, recall ve F1-score değerlerini görselleştirir.

B Planı: Simülasyonda beklenen başarım sağlanamazsa, Roboflow veri setine daha fazla CARLA sentetik veri eklenecek ve model yeniden eğitilecektir.

2. TEORİK ALTYAPI

2.1. Genel Bilgiler

Bu bölümde, geliştirilen otonom sürüş sisteminin temel bileşenlerini oluşturan teorik yapılar açıklanmaktadır. Sistem; çevresel algılama, risk analizi ve araç kontrolü olmak üzere üç ana katmandan oluşmaktadır. Her katman, bir sonraki katmana girdi sağlayan kapalı çevrim bir yapı içinde çalışmaktadır.

Aşağıdaki alt bölümlerde, her bir katmanın matematiksel temelleri ve kullanılan parametrelerin seçim gerekçeleri detaylandırılmıştır.

2.2. Görüntü İyileştirme ve Nesne Tespiti

2.2.1. Nesne Tespiti — YOLO

YOLO [26], görüntüyü tek aşamada işleyerek her bölgede nesne olma olasılığı, sınıf tahmini ve konum bilgisi üretir. Bu çalışmada YOLOv11 [15] kullanılmış, Roboflow [13]'dan elde edilen 7 sınıflı veri setiyle fine-tuning uygulanmıştır.

Sonrası Filtreleme: Kodda bina duvarı, billboard ve gökyüzündeki yanlış tespitleri engellemek için aspect ratio, konum ve boyut filtreleri uygulanır. Örneğin çok yatay kutu ($h/w<0.30$) bina yüzeyi olarak elenir.

2.2.2. Görüntü İyileştirme — DehazeFormer

Sisli görüntüler, atmosferik saçılma nedeniyle kontrast kaybı yaşar. DehazeFormer [12], Transformer mimarisinin self-attention mekanizması ile görüntüdeki uzamsal ilişkileri modelleyerek sis etkisini azaltır.

Kodda uygulanan pipeline: model çıktısı → gamma düzeltme → CLAHE (yerel kontrast) → unsharp masking → orijinal ile karıştırma. Bu adımlar, doğal görünümü korurken kontrastı artırır.

2.3. LiDAR Veri İşleme ve Mesafe Analizi

2.3.1. Nokta Bulutu Filtreleme

LiDAR verisi araç merkezli koordinat sistemindedir (x : ileri, y : sağ-sol, z : yukarı). Filtreleme adımları:

Şerit filtresi: Sadece $x>1.5$ m, $|y-y_{offset}|<1.05$ m ve $-0.3<z<1.2$ m aralığındaki noktalar tutulur. Bu, kendi şeridini ve yol düzeyini seçer.

Bina filtresi: Yan yayılımı geniş (>2.5 m) ama derinliği dar (<<1.5 m) olan kümeler bina duvarı olarak elenir.

2.3.2. Mesafe ve TTC Hesaplaması

EMA Filtreleme: Ani dalgalanmaları azaltmak için üstel hareketli (EMA) [31] uygulanır. Verilerdeki ani dalgalanmaları önlemek için Denklem (1) kullanılmıştır.

$$d_{EMA}(t) = \alpha \cdot d_{raw}(t) + (1-\alpha) \cdot d_{EMA}(t-1) \quad \text{Denklem (1)}$$

α=0.30 seçilmiştir; yeni ölçüme %30 ağırlık vererek hızlı tepki ile gürültü filtreleme arasında denge kurar.

Time-To-Collision (TTC) [2] Aracın çarpışma süresi, Denklem (2)'de belirtilen yöntemle hesaplanmıştır**:**

$$\mathrm{TTC} = \frac{d_{EMA}}{v_{closing}} \quad \text{Denklem (2)}$$

Yaklaşma hızı $v_{closing}>0.3$ m/s olduğunda hesaplanır, aksi halde sonsuz kabul edilir (duran/uzaklaşan nesneler için yanlış alarm önleme).

2.4. Risk Hesaplama ve Karar Verme

2.4.1. Risk Skoru

Risk skoru, dört bileşenin ağırlıklı toplamıdır. Sistemdeki toplam risk skoru, Denklem (3) kullanılarak hesaplanmaktadır.

$$R = 0.30 \cdot R_{LIDAR} + 0.20 \cdot R_{TTC} + 0.50 \cdot R_{YOLO} + 0.10 \cdot R_{TL}$$ Denklem (3)

Ağırlıkların seçim gerekçeleri:

YOLO (0.50): En yüksek ağırlık, çünkü sınıf bilgisi (yaya, araç, engel) içerir ve farklı nesnelere farklı tepki gerektirir.

LiDAR (0.30): Mesafe doğrudan çarpışma olasılığını belirler.

TTC (0.20): Dinamik riski yakalar; uzak ama hızla yaklaşan araçları tespit eder.

Trafik Işığı (0.10): Kırmızı/sarı durumunda durma zorunluluğu.

Sistemin karar verme sürecinde kullanılan mesafe ve TTC eşik değerleri Tablo 5'te sunulmuştur.

Tablo 5. Mesafe ve TTC değerlerine göre belirlenen eşik değerleri

Parametre	Acil	Sert Fren	Yavaş Fren	Dikkat	Güvenli
Mesafe (m)	< 5	< 12	< 20	< 35	≥ 35
TTC (s)	< 1,0	< 2,5	< 4,0	< 6,0	≥ 6,0

YOLO Bileşeni: Nesne boyutu ve konumuna göre katkı değişir. Merkezdeki ($185<cx<455$) büyük yaya en yüksek riski üretir (0.35), kenardaki küçük nesne en düşüğü (0.01).

Zamansal Yumuşatma: Son 8 karenin ortalaması alınarak ani dalgalanmalar önlenir.

2.5. Araç Kontrol Sistemleri

2.5.1. PID Hız Kontrolü

PID [3] kontrolcü, hedef hız ile gerçek hız arasındaki hatayı minimize eder. Hız kontrolü sürecinde kullanılan PID algoritması Denklem (4)'te gösterilmiştir.

$$u(t) = K_p \cdot e(t) + K_i \int e(t)dt + K_d \frac{de(t)}{dt}$$ Denklem (4)

Kazançlar: Kp=0.32 , Ki=0.006 , Kd=0.10 . İntegral terimi [−20,20] ile sınırlandırılmıştır (wind-up önleme).

Hedef hız, karar motorundan gelen değerin %65'i ile önceki yumuşatılmış değerin %35'i birleştirilerek ani değişimler engellenir.

2.5.2. Direksiyon Kontrolü — Waypoint Takibi ve CTE Düzeltmesi

İki bileşen birleştirilir:

Waypoint Heading Error [28]: İlerideki waypoint'lerin ağırlıklı ortalaması (orta nokta %40, son nokta %60) hedef olarak belirlenir. Araç-hedef arası açı farkı (angle_to - yaw) -π ile +π arası normalize edilerek yön hatası elde edilir.

CTE (Şerit Sapması) [29]: Araç ile şerit merkezi arasındaki lateral mesafe. Hıza bağlı kazanç: düşük hızda (<<20 km/h) 1.10 (agresif düzeltme), yüksek hızda (>20 km/h) 0.80 (yumuşak). Üst sınır 0.55 rad ile aşırı salınım önlenir.

Fusion: Yön hatası ile CTE düzeltmesi toplanarak PID girişi oluşturulur. Çıkış, hıza bağlı yumuşatma katsayısıyla filtrelenir: düşük hızda 0.25 (hızlı tepki), yüksek hızda 0.75 (stabil davranış).

2.6. Trafik Işığı Algılama — Fusion

Birincil kaynak: CARLA API (is_at_traffic_light()). Araç ışık bölgesindeyse, mesafe < 55 m ve görüş açısı > 0.65 koşullarında ışık durumu sorgulanır. API "Red" → tl_stop, "Yellow" → caution moduna geçilir.

İkincil kaynak: YOLOv11 + HSV renk analizi. API "Green" dediğinde, merkez bölgede ve yeterince büyük sinyal kutuları HSV uzayında analiz edilir. YOLO "Red" görürse caution (yavaşlama), "Yellow" görürse yoksayılır. Böylece geçiş dönemlerinde muhafazakar davranılır, ancak gereksiz durma önlenir.

API önceliklidir. YOLO asla tek başına durma kararı veremez, sadece yavaşlama uyarısı üretir.

3. TASARIM

3.1. Genel Bilgiler

Tasarım bölümünde, sisli hava koşullarında çalışan otonom sürüş sisteminin yazılım mimarisi, bileşen seçimleri ve parametre optimizasyonu ele alınmaktadır. Sistem, algılama, karar verme ve kontrol katmanlarının gerçek zamanlı senkronizasyonunu sağlayacak şekilde modüler yapıda tasarlanmıştır.

Temel Tasarım Prensipleri:

Sensör füzyonu: Kamera ve LiDAR verileri birleştirilerek tek sensörün zayıflıkları telafi edilir.

Hiyerarşik karar verme: Yaya> trafik ışığı > araç > engel öncelik sırasıyla risk değerlendirmesi yapılır.

Yumuşak geçişler: Hız ve direksiyon değişimleri ani değil, PID filtreleme ile kademeli gerçekleşir.

3.2. Sistem Bileşenleri ve Seçimleri

3.2.1. CARLA Simülasyon Ortamı

Projede gerçek dünya sürüş senaryolarının güvenli şekilde test edilebilmesi amacıyla CARLA simülasyon ortamı kullanılmıştır. CARLA; gerçekçi şehir yapıları, trafik sistemi, sensör desteği ve Python API desteği sağlaması nedeniyle tercih edilmiştir. Çalışmada Town10HD haritası kullanılarak şehir içi trafik senaryoları oluşturulmuştur.

3.2.2. RGB Kamera Sensörü

Araç ön görüntüsünün elde edilmesi amacıyla RGB kamera sensörü kullanılmıştır. Kamera çözünürlüğü 640×360 piksel olarak belirlenmiştir. Geniş çevre algısı sağlamak amacıyla görüş açısı (FOV) değeri 100 derece seçilmiştir. Kamera verileri nesne tespiti ve görüntü iyileştirme işlemlerinde kullanılmaktadır.

3.2.3. LiDAR Sensörü

Çevrede bulunan nesnelerin mesafe bilgilerinin elde edilmesi amacıyla LiDAR sensörü kullanılmıştır. Kullanılan LiDAR sensörü; 50 metre algılama menziline, 32 kanal yapısına, saniyede 56000 nokta üretim kapasitesine sahiptir.

LiDAR sensörü özellikle sisli hava koşullarında kamera sistemlerine göre daha güvenilir mesafe ölçümü sağladığı için tercih edilmiştir.

3.2.4. YOLO Nesne Tespit Modeli

Gerçek zamanlı nesne tespiti amacıyla YOLO tabanlı derin öğrenme modeli kullanılmıştır. Model; araç, insan, trafik ışığı, hız tümseği, çukur, engel, hayvan gibi nesneleri algılayabilecek şekilde eğitilmiştir.

Model eğitiminde kullanılan veri setleri Roboflow platformu üzerinden elde edilmiştir. Veri setleri; BDD100K, ACDC, Animals, Pothole, More-SpeedBump, Debris, Road Debris, Barrier kullanılmıştır.

Özellikle ACDC veri setindeki sisli, yağmurlu ve gece görüntüleri sistem performansının artırılmasında kullanılmıştır.

3.2.5. DehazeFormer Görüntü İyileştirme Modeli

Sisli görüntülerde oluşan kontrast kaybını azaltmak amacıyla DehazeFormer-S modeli kullanılmıştır. Bu model sayesinde görüntü netliği artırılmış ve YOLO modelinin nesne tespit başarımı iyileştirilmiştir.

3.2.6. PID Kontrol Sistemi

Araç hız ve direksiyon kontrolü için PID kontrol algoritması kullanılmıştır. PID kontrol sistemi, araç hareketlerinin daha kararlı ve kontrollü gerçekleşmesini sağlamaktadır. Böylece ani hız değişimleri ve yön sapmaları azaltılmıştır.

3.3. Uygulanan Yöntemler

3.3.1. Sensör Veri Akışı ve Senkronizasyon

Sistem CARLA senkron modunda çalışmaktadır ve her tick 0.05 saniye (20 Hz) sürmektedir. Bu süre içinde kamera ve LiDAR sensörlerinden eşzamanlı veri alınmaktadır. İşlem yükünü dengelemek amacıyla DehazeFormer görüntü iyileştirme modülü her iki karede bir çalıştırılırken, YOLOv11 nesne algılama modülü her karede çalışmaktadır. İyileştirilmiş görüntüler bir sonraki karede YOLO girişi olarak kullanılmakta, böylece süreklilik korunmaktadır. Bu zaman paylaşımlı yaklaşım, hesaplama kaynaklarını verimli kullanarak düşük gecikmeli gerçek zamanlı performans sağlamaktadır.

3.3.2. Görüntü İyileştirme

DehazeFormer-S modeli, PyTorch framework'ü üzerinde çalışmaktadır. Model çıktısı sonrası kontrast artırımı, yerel histogram eşitleme ve kenar vurgulama adımları uygulanmaktadır. Gamma düzeltme ($\gamma = 1.15$) ile genel kontrast artırılır, CLAHE (clipLimit = 1.5, tileGridSize = 8×8) ile yerel detaylar güçlendirilir, unsharp masking ile kenarlar vurgulanır. Son olarak orijinal görüntü ile %15-%85 oranında karıştırma yapılarak doğal

görünüm korunur ve parlaklık ayarı ($\alpha = 1.04$, $\beta = 2$) uygulanır. Bu pipeline, sis etkisini azaltırken YOLOv11 için optimal giriş sağlamak amacıyla tasarlanmıştır.

3.3.3. Nesne Algılama ve Sonrası Filtreleme

YOLOv11 Ultralytics kütüphanesi kullanılarak çalıştırılmakta ve 7 sınıfta (person, vehicle, signal, pothole, speedbump, obstacle, animal) nesne tespiti gerçekleştirilmektedir. Model çıktısı sonrası yanlış pozitif tespitleri azaltmak için sınıf bazlı filtreleme uygulanmaktadır. Sinyal sınıfında çok yatay, çok küçük, çok büyük, görüntü kenarında veya düşük dikey oranlı kutular tabela veya gürültü olarak elenmektedir. Araç sınıfında ise çok büyük, görüntü üst kısmında, kenarda dev boyutlu veya düşük dikey oranlı kutular bina/duvar yüzeyi olarak filtrelenmektedir. İnsan sınıfında görüntünün çok üstünde veya çok geniş kutular billboard olarak değerlendirilmektedir. Bu filtreleme adımları, özellikle sisli koşullarda bina duvarları ve tabelaların yanlış araç/nesne olarak algılanmasını önlemektedir.

3.3.4. LiDAR Veri İşleme ve TTC Hesaplama

LiDAR nokta bulutu araç merkezli koordinat sisteminde (x: ileri, y: sağ-sol, z: yukarı) işlenmektedir. Öncelikle şerit filtresi uygulanarak minimum ileri mesafe, şerit yarı genişliği ve yükseklik aralığına göre noktalar seçilmektedir. Ardından bina ve duvar filtrelemesi yapılarak yan yayılımı geniş ancak derinliği dar olan kümeler elenmektedir. Kalan noktalardan mesafe hesaplanırken üstel hareketli ortalama (EMA, $\alpha = 0.30$) ile ani dalgalanmalar yumuşatılmaktadır. Time-To-Collision (TTC) yaklaşma hızının 0.3 m/s üzerinde olduğu durumlarda mesafe bölü yaklaşma hızı olarak hesaplanmakta, aksi halde güvenli değer olan 99.0 saniye atanmaktadır. Bu yaklaşım duran veya uzaklaşan nesneler için yanlış alarm oluşmasını önlemektedir.

3.3.5. Risk Skoru Hesaplama

Risk skoru LiDAR mesafesi, TTC, YOLO tabanlı nesne tespitleri ve trafik ışığı durumunun ağırlıklı birleşiminden oluşmaktadır. LiDAR ve TTC bileşenleri mesafe ve zaman eşiklerine göre kademeli skorlar üretmekte, nesne sınıfları ise konum ve boyutlarına göre farklı katkılar sağlamaktadır. Yaya sınıfı merkezde ve büyük tespit edildiğinde en yüksek katkıyı (0.35) verirken, kenarda ve küçük tespitler minimum katkıda bulunmaktadır. Araç sınıfı benzer şekilde merkezde ve büyük olduğunda yüksek katkı sağlamakta, trafik ışığı ise kırmızı durumda tam risk (0.10), sarı durumda kısmi uyarı (0.03) üretmektedir. Son

8 karenin ortalaması alınarak zamansal yumuşatma uygulanmakta ve ani dalgalanmalara karşı robust kararlar alınmaktadır.

3.3.6. Adaptif Karar Mekanizması

Karar motoru hiyerarşik öncelik sırasına göre çalışmaktadır. Yaya tespiti en yüksek önceliğe sahip olup merkezde yakın mesafede emergency moduna geçiş sağlamaktadır. Trafik ışığı kırmızı durumunda tl_stop aktif olmakta, mesafe ve TTC eşikleri ise sert fren, yavaş fren ve dikkat modları arasında geçişleri belirlemektedir. Speedbump tespiti yavaşlama moduna, güvenli durumlar ise normal sürüşe izin vermektedir. Tüm kaynaklardan gelen hız sınırlamalarının minimumu alınarak en muhafazakar karar benimsenmekte, modlar ise en yüksek öncelikli olanı seçilmektedir. Bu yapı karmaşık trafik senaryolarında dinamik ve güvenli mod geçişleri sağlamaktadır.

3.3.7. Araç Kontrolü

Hız kontrolü PID algoritması ile gerçekleştirilmekte, oransal, birikimsel ve türevsel terimlerin birleşimiyle hedef hız ile gerçek hız arasındaki fark minimize edilmektedir. İntegral terimi sınırlandırılarak wind-up etkisi önlenmekte, hedef hız yumuşatma filtresi ile ani değişimler engellenmektedir. Direksiyon kontrolünde ise yol geometrisine dayalı yön hatası ile şerit sapması (CTE) düzeltmesi toplanarak PID girişi oluşturulmaktadır. Hıza bağlı kazanç ayarı ile düşük hızlarda agresif, yüksek hızlarda yumuşak şerit merkezileme sağlanmakta, CTE düzeltme üst sınırı ile aşırı salınım önlenmektedir. Waypoint takibinde ileri bakış mesafesi hızla dinamik olarak ayarlanmakta, ağırlıklı çoklu hedef nokta kullanılarak pürüzsüz yörünge izlenmektedir.

3.3.8. Trafik Işığı Algılama

Trafik ışığı algılama iki kaynağın füzyonu ile gerçekleştirilmektedir. Birincil kaynak CARLA API olup araç ışık bölgesindeyse mesafe ve görüş açısı koşullarında durum sorgulanmaktadır. API kırmızı durumunda durma, sarı durumunda yavaşlama, yeşil veya bilinmeyen durumda güvenli geçiş sağlanmaktadır. İkincil kaynak YOLOv11 tespiti ve HSV renk analizi olup API'nin yeşil bildirdiği ancak görsel olarak riskli göründüğü durumlarda devreye girmektedir. Sadece merkez bölgede ve yeterince büyük sinyal kutuları değerlendirilmekte, kırmızı piksel baskınlığı tespit edilirse hafif uyarı moduna geçilmektedir. Sarı tespiti güvenilirliği düşük olduğundan yoksayılır ve YOLO asla tek başına durma kararı veremez.

3.3.9. Validasyon ve Telemetri

Validasyon Manager modülü her 10 karede bir çalışarak CARLA ground truth verisi ile YOLO tespitleri arasında çapraz doğrulama yapmaktadır. Trafik ışıkları için 60 metre, diğer nesneler için 45 metre mesafe eşiği uygulanmakta, görüş açısı kontrolü ile yanlış pozitifler minimize edilmektedir. Precision, recall ve F1-score metrikleri sınıf bazında hesaplanmaktadır. Telemetri modülü ise her karede hız, risk skoru, TTC, mesafe, çalışma modu, trafik ışığı durumu, gaz, fren ve direksiyon değerlerini kaydetmekte, uzun süreli testlerin analizine olanak tanımaktadır.

3.4. Yazılımlar

3.4.1. Genel Yazılım Mimarisi

Bu çalışmada geliştirilen otonom sürüş sistemi, CARLA simülasyon ortamı üzerinde çalışan gerçek zamanlı ve modüler bir yazılım mimarisine sahiptir. Sistem; algılama, sensör füzyonu, risk analizi, karar verme ve kontrol olmak üzere çok katmanlı bir yapı üzerine kurulmuştur.

Yazılım senkron çalışma prensibi ile tasarlanmış olup sabit zaman adımı (fixed delta time) kullanılarak simülasyon ile gerçek zamanlı davranış uyumu sağlanmıştır. Sensör verileri eş zamanlı olarak işlenmekte ve tüm karar mekanizması tek bir kontrol döngüsü içerisinde yürütülmektedir.

3.4.2. Yazılım Modülleri

Sistem fonksiyonel olarak birbirinden bağımsız ancak veri akışı açısından birbirine bağlı modüllerden oluşmaktadır.

PIDController Modülü, araç hız kontrolü ve direksiyon kontrolünde kullanılan kapalı çevrim kontrol yapısını gerçekleştirmektedir. Hedef hız ile anlık hız arasındaki hata PID algoritması ile işlenerek gaz ve fren çıktıları üretilmektedir.

LidarProcessor Modülü, LiDAR sensöründen gelen nokta bulutu verilerini işleyerek çevresel mesafe bilgisi üretmektedir. Bu modülde şerit tabanlı filtreleme, yükseklik sınırlandırma, EMA filtreleme ve Time-to-Collision (TTC) hesaplaması gerçekleştirilmektedir.

RiskScorer Modülü, LiDAR mesafesi, TTC değeri, YOLO tabanlı nesne tespitleri ve trafik ışığı durumu gibi çoklu girdileri ağırlıklı olarak birleştirerek sürekli bir risk skoru üretmektedir.

DecisionEngine Modülü, hesaplanan risk skoru ve algısal çıktılara bağlı olarak aracın sürüş durumunu belirlemektedir. Sistem “go”, “caution”, “soft_brake”, “hard_brake” ve “tl_stop” gibi karar durumları üretmektedir.

ValidationManager Modülü, YOLO tabanlı nesne tespit performansını değerlendirmek amacıyla precision, recall ve F1-score metriklerini hesaplamakta ve ground truth verileri ile karşılaştırma yapmaktadır.

Telemetry Modülü, sistemin çalışma sürecine ait hız, risk skoru, TTC, direksiyon açısı ve kontrol sinyallerini kayıt altına alarak analiz edilebilir veri seti oluşturmaktadır.

3.4.3. Algoritmik Yapı ve İş Akışı

Sistem çalışması çevrimsel bir kontrol döngüsü şeklinde ilerlemektedir. Her zaman adımında sensör verileri alınmakta, ön işleme uygulanmakta ve karar üretimi gerçekleştirilmektedir.

Öncelikle kamera görüntüsü YOLO nesne tespit modeline ve görüntü iyileştirme (dehazing) sürecine tabi tutulmaktadır. Elde edilen nesne çıktıları konum ve boyut filtrelerinden geçirilerek sınıflandırılmaktadır. LiDAR verisi ise geometrik filtreleme ve istatistiksel süzme işlemleri sonrası mesafe ve TTC hesaplamasında kullanılmaktadır.

Bu çıktılar RiskScorer modülüne giriş olarak verilmekte ve tek bir risk metriğine dönüştürülmektedir. Ardından DecisionEngine, bu risk metriği ve çevresel koşulları değerlendirerek sürüş modunu belirlemektedir.

3.4.4. Direksiyon Kontrolü ve Şerit Takibi

Direksiyon kontrolü, Waypoint tabanlı takip yöntemi ve Cross Track Error (CTE) düzeltmesi kullanılarak gerçekleştirilmiştir. Araç, CARLA haritası üzerinde tanımlı şerit waypoint’lerini takip etmekte ve şerit merkezine olan yanal sapma hesaplanmaktadır.

CTE değeri ve araç yön açısı birlikte değerlendirilerek direksiyon girdisi üretilmektedir. Ayrıca ileriye dönük waypoint örneklemesi ile hedef nokta ağırlıklı olarak belirlenmiş ve daha kararlı bir yön takibi sağlanmıştır. Bu yapı sayesinde araç yalnızca anlık hedefe değil, şerit geometrisine uygun şekilde yönlendirilmiştir.

3.4.5. Sözde Kod (Pseudo Code)

Bu çalışmada geliştirilen yazılımın çalışma mantığını açıklamak amacıyla sözde kod oluşturulmuştur. Sözde kod, sistemin sensör verilerinin alınmasından başlayarak algılama, risk hesaplama, karar verme ve kontrol çıktılarının üretilmesine kadar olan temel iş akışını

özetlemektedir. Bu yapı, gerçek kod bağımsız olarak algoritmanın genel mantığını ortaya koymaktadır. Geliştirilen otonom sürüş sisteminin çalışma mantığını gösteren sözde kod Şekil 2'de sunulmuştur.

4.4. Algoritmanın Sözde Kodu (Pseudocode)

Algoritma 1: Sisli Ortamda Otonom Sürüş Sistemi (SÖSS)

```
Girdi: Araç kontrol komutları (throttle, brake, steer), sensör verileri
Başlat: CARLA simülasyonuna bağlan;
Senkron modu aktifleştir ve sabit zaman adımı ayarla;
Sisli hava parametrelerini ayarla;
YOLO nesne tespit modelini yükle;
DehazeFormer sis giderme modelini yükle;
PID kontrolörlerini başlat (speed_pid, steer_pid);
Risk skorlayıcı, karar motoru ve validasyon yöneticisini başlat;
Ego aracını ve sensörleri (kamera, LiDAR) oluştur;
NPC trafik aktörlerini oluştur;

while çıkış tuşuna basılana kadar:
  Dünya durumunu güncelle;
  Kamera kuyruğundan son görüntüyü al;
  if frame_count mod dehaze_skip == 0 then
    Görüntüyü DehazeFormer ile sis giderme;
    Gamma düzeltme, CLAHE ve bulanık kaldırma uygula;
    Orijinal görüntü ile karıştır ve ölçeklendir;
    İşlenmiş görüntüyü sakla;
  else
    Önceki işlenmiş görüntüyü kullan;
  end if
  LiDAR nokta bulutunu al ve örneklem;
  Şerit merkezi offset hesapla;
  Temel şerit filtresi uygula;
  Bina/duvar cluster filtresi uygula;
  Persentil mesafeyi EMA ile yumuşat;
  Kapama hızını EMA uygula ve TTC hesapla;
  if frame_count mod yolo_skip == 0 then
    YOLO track modunu sis giderilmiş görüntüde çalıştır;
    Tespit edilen kutuları sınıf atamalarına göre ayrıştır;
        SIGNAL filtresi uygula;
        VEHICLE filtresi uygula;
        PERSON filtresi uygula;
        OBSTACLE filtresi uygula;
    Tespit sayılarını ve kutu detaylarını sakla;
  else
    Son tespit sonuçlarını kullan;
  end if
  Trafik ışığı durumunu kontrol et (CARLA API + YOLO fusion);
  Risk skorunu çok kriterli olarak hesapla;
      LiDAR mesafe ve TTC bileşeni;
      YOLO PERSON bileşeni;
      YOLO VEHICLE bileşeni;
      TRAFFIC LIGHT bileşeni;
```

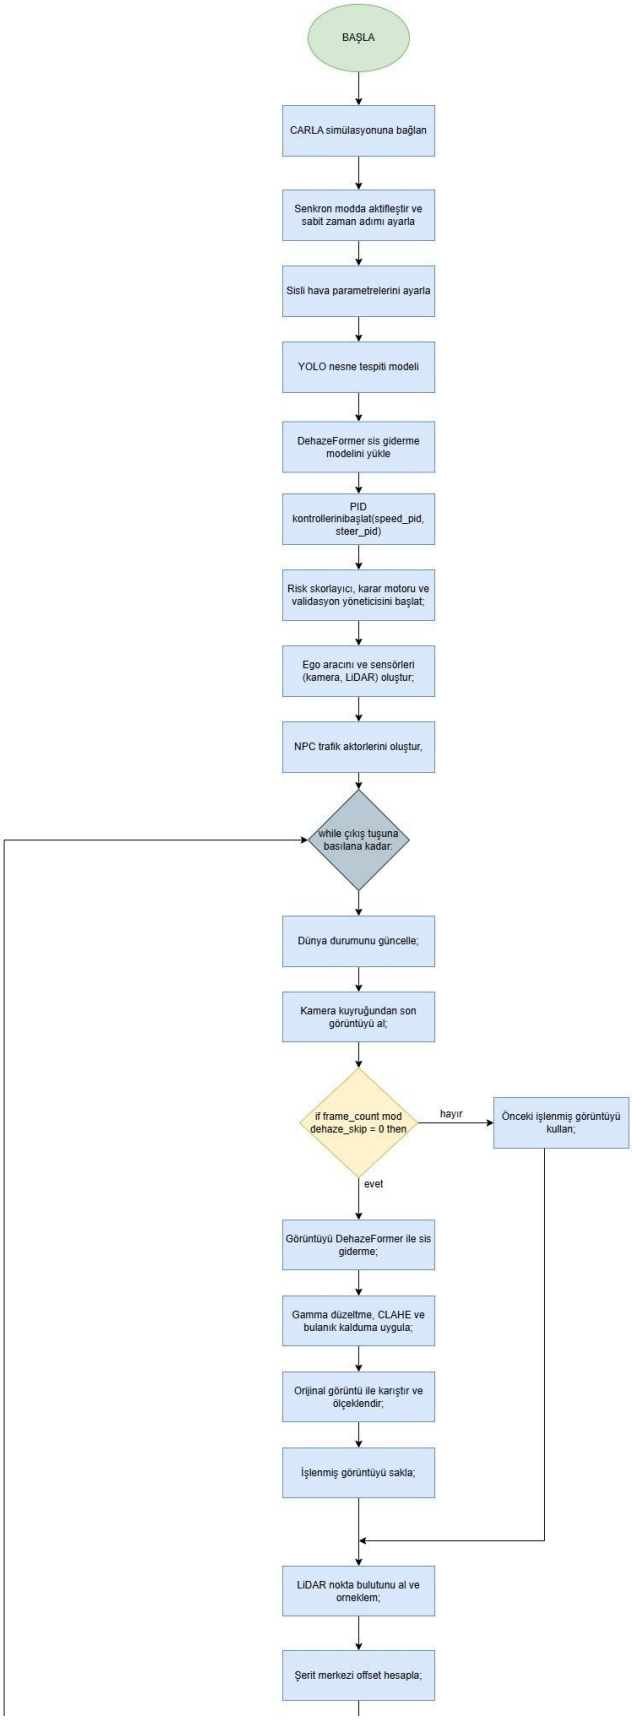
Şekil 2. Önerilen sistemin genel algoritmasına ait sözde kod (Kısım 1)

```
36.       Hareketli ortalama ile yumuşat;
37.       Araç takip kararını (mesafe/TTC bazlı) hesapla;
38.       Yaya kararını (mesafe/boyut bazlı) hesapla;
39.       Trafik ışığı kararını hesapla;
40.       Yol tehlikesi kararını hesapla;
41.       Risk skoruna göre global hız sınırını belirle;
42.       Hedef hız ← en düşük alt-kısıt hızı;
43.       Nihai mod ← en yüksek öncelikli alt-karar;
44.       if mod == emergency veya mod == hard_brake then
45.         throttle ← 0, brake ← maksimum, PID sıfırla;
46.       else if mod == tl_stop then
47.         throttle ← 0, brake ← hız orantılı, PID sıfırla;
48.       else
49.         Hedef hızı EMA ile yumuşat;
50.         Hız hatası ← hedef_hız - mevcut_hız;
51.         PID çıktısı ← speed_pid.step(hata, dt);
52.         if PID çıktısı > 0 then
53.           throttle ← çıktı (limitli), brake ← 0;
54.         else
55.           throttle ← 0, brake ← |çıktı|;
56.           if mod != hard_brake then
57.             brake ← brake × smoothing_faktör;
58.           end if
59.         end if
60.       end if
61.       Hedefe göre ön bakış mesafesini belirle;
62.       Hızla dinamik ön bakış hesapla;
63.       Araç konumundan şeride eşit aralıklarla waypoint'leri al;
64.       Hedef noktayı ağırlıklı ortalama ile belirle;
65.       Şerit merkezi CTE (Cross Track Error) hesapla;
66.       Heading hatası hesapla;
67.       Toplam hata ← heading_hatası + cte_düzeltmesi;
68.       Direksiyon ← steer_pid.step(toplam_hata, dt);
69.       Direksiyon smoothing uygula (hıza bağlı);
70.       Direksiyon ← α×önceki + (1-α)×yeni, limitli;
71.       Araç kontrol komutlarını uygula;
72.       Telemetri verilerini kaydet;
73.       if frame_count mod validation_skip == 0 then
74.         Gerçek değerleri topla;
75.         Precision, Recall ve Accuracy metriklerini güncelle;
76.       end if
77.       if frame_count mod cleanup_interval == 0 then
78.         Ölü aktörleri temizle;
79.       end if
80.       if q tuşu basıldı then
81.         break;
82.       end if
83.       frame_count ← frame_count + 1;
84. end while
85. Tüm aktörleri yok et;
86. Validasyon raporunu ve telemetri özetini yazdır;
87. Validasyon grafiklerini kaydet;
88. return Sistem sonlandı;
```

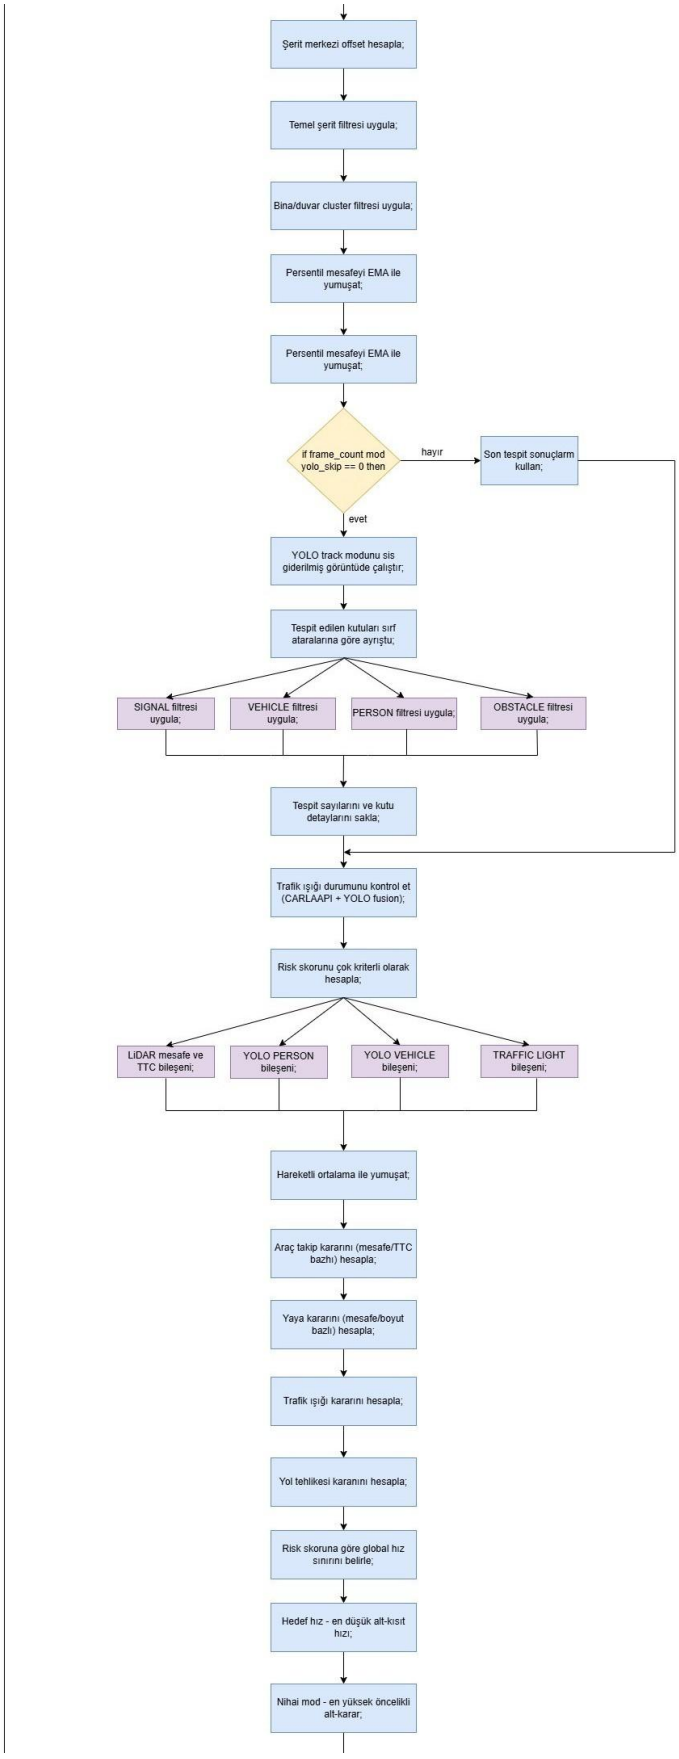
Şekil 2. Önerilen sistemin genel algoritmasına ait sözde kod (Kısım 2)

3.4.6. Akış Diyagramı Açıklaması

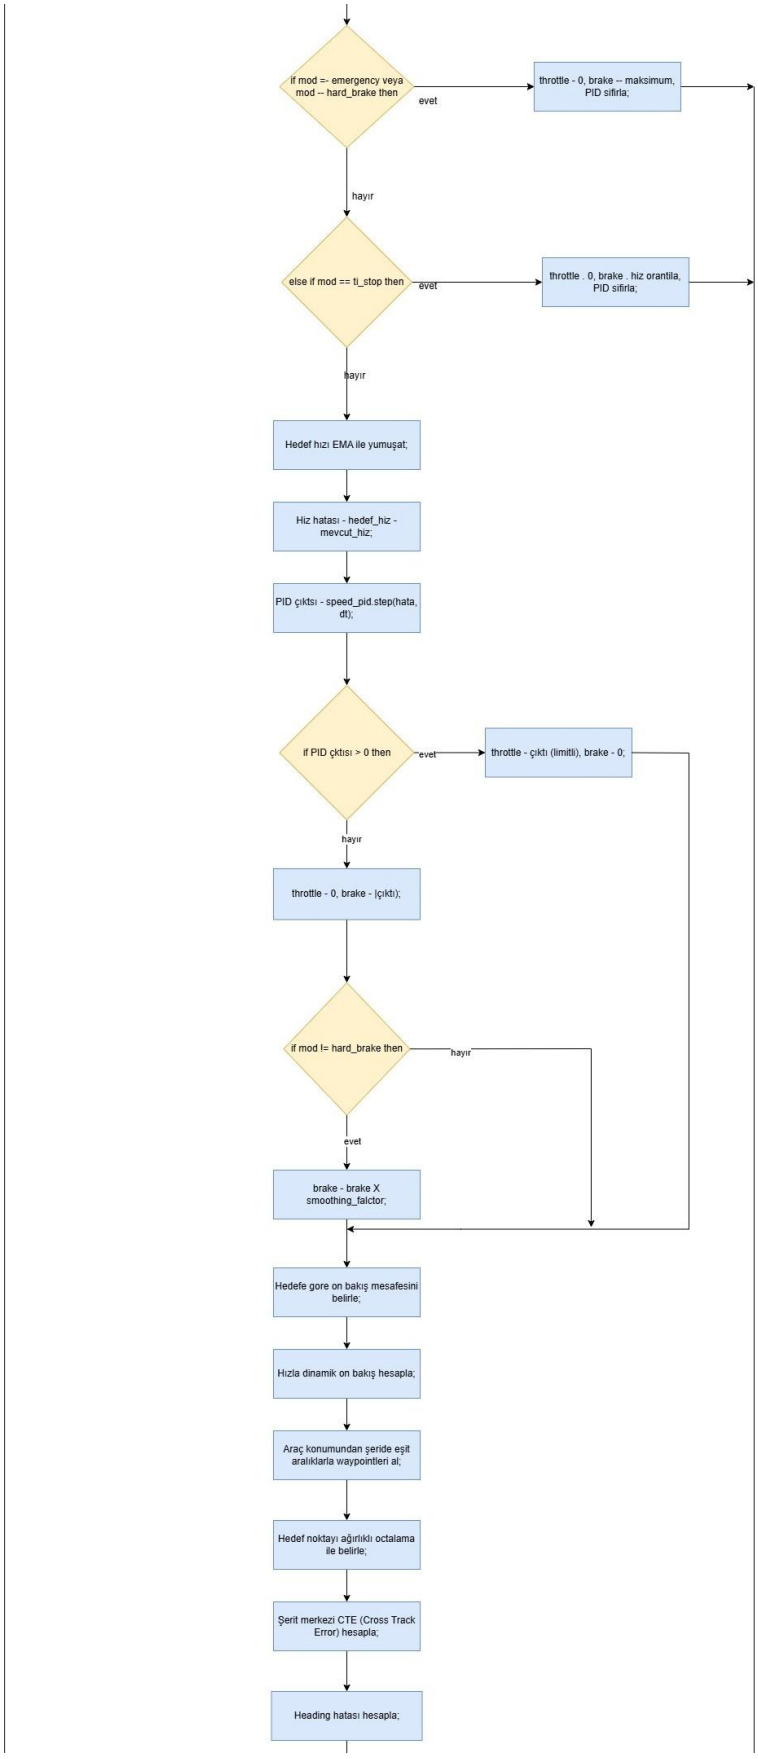
Sistem çalışma akışı Şekil X'te verilen akış diyagramı ile gösterilmiştir. Diyagramda sensörlerden veri alınması, görüntü işleme ve LiDAR filtreleme adımları, sensör füzyonu ile risk hesaplama süreci ve son olarak karar verme ile araç kontrolü aşamaları sıralı olarak sunulmaktadır. Bu yapı, sistemin çevrimsel (loop-based) çalışma mantığını ve gerçek zamanlı karar üretme mekanizmasını göstermektedir. Sistem çalışma akışı Şekil 3'te verilen akış diyagramı ile gösterilmiştir.



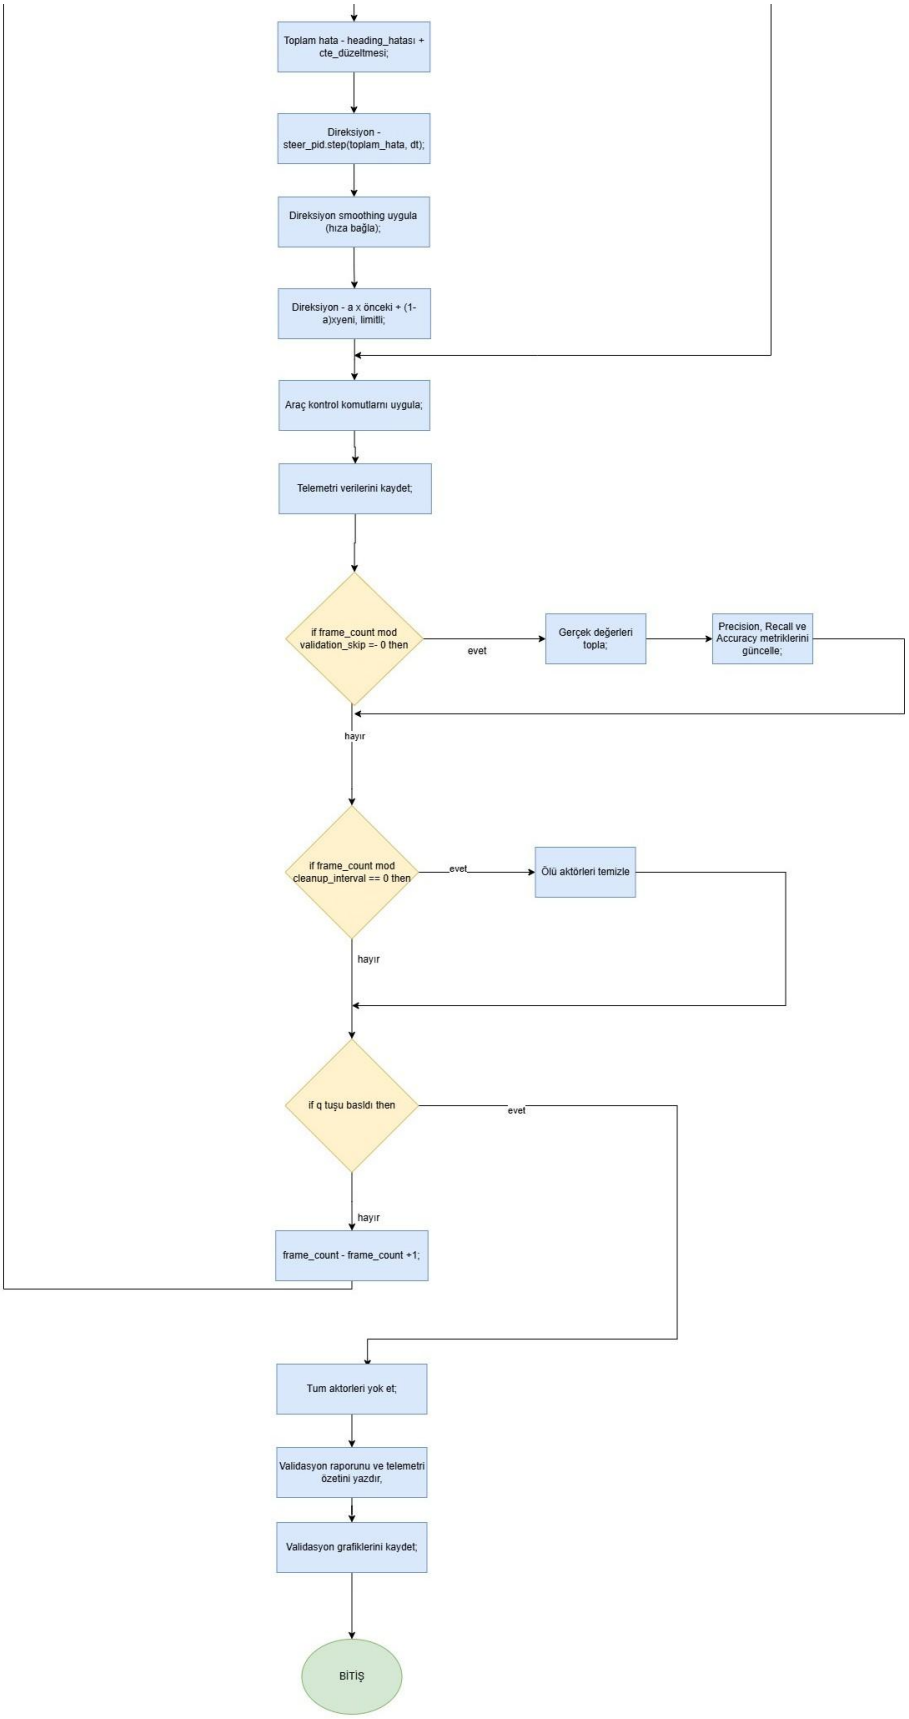
Şekil 3. Otonom sürüş sisteminin genel çalışma akış diyagramı (Kısım1)



Şekil 3. Otonom sürüş sisteminin genel çalışma akış diyagramı (Kısım 2)



Şekil 3. Otonom sürüş sisteminin genel çalışma akış diyagramı (Kısım 3)



Şekil 3. Otonom sürüş sisteminin genel çalışma akış diyagramı (Kısım 4)

3.5. Malzeme Listesi ve Ekonomik Analiz

Bu çalışma simülasyon tabanlı olarak gerçekleştirildiğinden fiziksel donanım bileşenleri kullanılmamıştır. Bu nedenle klasik anlamda bir malzeme listesi ve donanım maliyeti bulunmamaktadır.

Sistem, CARLA simülasyon ortamı, YOLO tabanlı nesne tespit modeli, DehazeFormer derin öğrenme modeli ve Python tabanlı yazılım kütüphaneleri (PyTorch, OpenCV, NumPy) kullanılarak geliştirilmiştir.

Çalışma kapsamında tüm bileşenlerin açık kaynaklı yazılımlar olması nedeniyle ek bir lisans veya donanım maliyeti oluşmamıştır. Bu durum, sistemin düşük maliyetli ve yeniden üretilebilir bir araştırma platformu olarak uygulanabilirliğini artırmaktadır.

4. SİMÜLASYON (BENZETİM) ÇALIŞMALARI

Sistem, gerçek dünyada test edilmesi riskli ve maliyetli olan senaryoları güvenli bir ortamda tekrarlanabilir şekilde değerlendirmek amacıyla CARLA simülatöründe test edilmiştir. Simülasyon, otonom sürüş algoritmalarının geliştirilmesinde kritik bir araçtır çünkü trafik kazaları, ani engel çıkışları ve zorlu hava koşulları gibi durumlar sanal ortamda binlerce kez tekrarlanabilir.

CARLA'nın senkron modu kullanılarak her 50 milisaniyede bir deterministik adım atılması sağlanmıştır. Bu, aynı senaryonun tekrar tekrar çalıştırıldığında aynı sonucu vermesini garanti eder ve hata ayıklama sürecini kolaylaştırır. Tesla Model 3 aracı üzerine yerleştirilen kamera ve LiDAR sensörleri, gerçek araçlardaki konumlara benzer şekilde ön cam üstüne ve tavana monte edilmiştir.

4.1. Simülasyon Yazılımı

4.1. Genel Bilgiler

Bu çalışmada, geliştirilen Sisli Ortamda Otonom Sürüş Sistemi'nin (SÖSS) performansını güvenli ve tekrarlanabilir koşullarda değerlendirmek amacıyla kapsamlı bir simülasyon çalışması gerçekleştirilmiştir. Simülasyonların temel hedefi; sisli hava koşullarında sistemin nesne algılama, risk değerlendirme, karar verme ve kontrol mekanizmalarının işlevselliğini test etmek, ayrıca farklı trafik senaryoları altında robustlığını doğrulamaktır.

Simülasyon çalışmaları, açık kaynak CARLA otonom sürüş simülatörü üzerinde gerçekleştirilmiş olup; deterministik koşulların sağlanması için senkron modda çalışılmıştır. Tüm senaryolarda sabit zaman adımı kullanılarak sistematik ve karşılaştırılabilir sonuçlar elde edilmiştir. Simülasyon kapsamında; farklı görüş mesafeleri, trafik yoğunlukları ve yaya davranışları altında sistem performansı ölçülmüş, elde edilen metrikler bir sonraki bölümde detaylı olarak sunulmuştur.

4.2. Simülasyon Yazılımı

4.2.1. CARLA Simülatörü

Simülasyon ortamı olarak CARLA (Car Learning to Act) versiyon 0.9.x kullanılmıştır. CARLA, Unreal Engine 4/5 grafik motoru üzerine kurulu, açık kaynaklı ve akademik/bilimsel çalışmalara yönelik geliştirilmiş yüksek doğruluklu bir otonom sürüş simülatörüdür. Simülatör; fizik tabanlı araç dinamiği, gerçekçi sensör modelleri, çeşitli hava ve aydınlatma koşulları, zengin trafik aktörü kütüphanesi ve Python/C++ API desteği ile otonom sürüş algoritmalarının geliştirilmesi ve test edilmesi için ideal bir platform sunmaktadır.

Çalışmada Town10HD haritası tercih edilmiş olup, bu harita; gerçek dünya kent dokusuna yakın karmaşık yol geometrileri, çok şeritli kavşaklar, trafik ışıkları ve çeşitli yapı tipleri (yüksek binalar, köprüler, tüneller) içermektedir. Haritanın yüksek detaylı olması, sisli koşullarda bina duvarları ve çevre nesnelerinin yanlış algılanması riskini artırarak sistemin filtreleme yeteneklerinin gerçekçi şekilde test edilmesini sağlamıştır.

4.2.2. Sensör Yapılandırması

Simülasyonda ego araca iki temel sensör monte edilmiştir:

RGB Kamera: Ön cepheye yerleştirilmiş olup, 640×480 piksel çözünürlükte görüntü üretmektedir. Kamera, araç gövdesine göre (x=1.6 m, z=1.7 m) konumlandırılmış ve 100° yatay görüş açısına (FOV) sahiptir. Kamera verileri, nesne tespiti ve trafik ışığı tanıma görevlerinde kullanılmıştır.

LiDAR: 32 kanallı, 50 m menzilli, 56.000 nokta/saniye veri üretim hızına sahip LiDAR sensörü (x=1.6 m, z=2.0 m) konumlandırılmıştır. LiDAR, 20 Hz dönüş frekansında çalışmakta olup; ön şeritteki engellerin mesafe ve hız tahmini (TTC hesaplaması) için kullanılmıştır.

4.2.3. Hava Koşulları ve Sis Modellemesi

Simülasyonların temel değişkeni olan sisli hava koşulları, CARLA'nın WeatherParameters arayüzü üzerinden modellenmiştir. Sis modellemesinde; yoğunluk (fog density), görüş mesafesi (fog distance), düşüş oranı (fog falloff), bulutluluk (cloudiness) ve nemlilik (wetness) parametreleri kullanılarak gerçekçi atmosferik saçılma etkileri oluşturulmuştur. Sis parametreleri sabit tutularak sistematik karşılaştırma imkanı sağlanmış, ayrıca farklı sis yoğunluklarında ek testler gerçekleştirilmiştir.

4.3. Sistem Modelleme

4.3.1. Ego Araç Modeli

Simülasyonda Tesla Model 3 baz alınarak modellenmiş araç kullanılmıştır. Araç dinamiği, CARLA'nın fizik motoru tarafından gerçekçi kütle, sürtünme ve direksiyon tepkisi parametreleri ile simüle edilmiştir. Ego araç, geliştirilen SÖSS yazılımı tarafından throttle, brake ve steer komutları ile kontrol edilmiş olup; bu komutlar her simülasyon adımında (dt = 0.05 s) hesaplanarak simülatöre iletilmiştir.

4.3.2. Çevre ve Trafik Modellemesi

Simülasyon ortamı, gerçekçi trafik koşullarını yansıtacak şekilde modellenmiştir:

NPC Araçlar: 30 adet otonom araç, CARLA Traffic Manager (TM) tarafından kontrol edilmek üzere haritada rastgele spawn noktalarına yerleştirilmiştir. TM, araçlar arası güvenli takip mesafesi (3.5 m), hız limitlerine uyum ve şerit disiplini sağlayarak gerçekçi trafik akışı oluşturmuştur.

Yaya Aktörleri: 60 adet yaya, AI kontrolcüleri ile navigasyon grafiği üzerinde rastgele hedeflere yürüyecek şekilde modellenmiştir. Yaya hızları 1.0–3.2 m/s aralığında rastgele atanmış, yaya davranışları ise kaldırımlar ve geçitler dahil olmak üzere gerçekçi şekilde simüle edilmiştir.

Trafik Altyapısı: Trafik ışıkları, CARLA'nın yerleşik sinyalizasyon sistemi ile modellenmiş olup; kırmızı, sarı ve yeşil fazları gerçek zamanlı olarak değişmektedir. Trafik ışıklarının konumları ve durumları, sistemin sinyalizasyon kararlarını test etmek için kullanılmıştır.

4.3.3. Validasyon Modeli

Simülasyon sırasında sistem performansının objektif değerlendirilmesi amacıyla bir

validasyon modeli entegre edilmiştir. Bu model, her 10 karede bir (0.5 s aralıklarla) şu metrikleri hesaplamaktadır:

Precision: Doğru pozitif tespitlerin, toplam pozitif tespitlere oranı

Recall: Doğru pozitif tespitlerin, gerçek pozitif sayısına oranı

Accuracy: Precision ve Recall'un ortalaması

Validasyon, CARLA dünya koordinatlarında gerçek aktör konumları ile SÖSS algılama sonuçlarının karşılaştırılması prensibine dayanmaktadır. Gerçek değerler (ground truth), simülatörün içsel aktör listesinden elde edilmiş olup; her aktör için sınıf etiketi (araç, yaya, trafik ışığı), konum ve yönelim bilgileri kullanılarak 45 m (trafik ışıkları için 60 m) yarıçapında ve araç bakış açısı içinde kalan aktörler referans alınmıştır.

5. DENEYSEL ÇALIŞMALAR

5.1. Genel Bilgiler

Deneysel çalışmalar, simülasyon ortamında geliştirilen algoritmaların gerçek zamanlı performansının değerlendirilmesini kapsamaktadır. CARLA simülatörü üzerinde kurulan yazılım-donanım entegrasyonu, sensör verilerinin işlenmesi, karar mekanizmasının test edilmesi ve görsel arayüz üzerinden sistem davranışının izlenmesini içermektedir.
Sistemin çalışma prensibi şöyledir: kamera ve LiDAR sensörlerinden eşzamanlı veri alınır, bu veriler paralel işleme hatları üzerinden değerlendirilir, elde edilen risk skoru ve kararlar araç kontrol birimine iletilir ve tüm süreç gerçek zamanlı olarak görsel arayüzde takip edilir.

5.2. Yazılım ve Donanım Ekipmanlarının Birleştirilmesi

Sistemin deneysel kurulumunda donanım tarafı simülasyon ortamında araç modeli, kamera ve LiDAR sensörlerinden oluşurken, yazılım tarafı algılama, karar verme ve kontrol modüllerinden oluşmaktadır.

CARLA API üzerinden araç ve sensörler Python tabanlı kontrol yazılımına bağlanmıştır. Kamera verileri gerçek zamanlı olarak alınarak YOLOv11 tabanlı nesne tespiti algoritmasına aktarılmış, LiDAR verileri ise mesafe ve çarpışma zamanı hesaplamalarında kullanılmıştır. Bu iki veri kaynağı birleştirilerek risk skoru üretilmiş ve bu skor doğrultusunda hız ve direksiyon komutları araç kontrol birimine iletilmiştir. Böylece sistem uçtan uca kapalı çevrim bir kontrol yapısı olarak çalıştırılmıştır.

Sensör verilerinin senkronizasyonu kritik öneme sahiptir. CARLA'nın senkron modunda her tick'te kamera ve LiDAR verileri aynı anda güncellenmektedir. Bu, algılama ve kontrol kararlarının tutarlı veri üzerinden alınmasını garanti eder. Asenkron modda sensörler farklı hızlarda çalışabileceğinden, LiDAR verisi kamera görüntüsünden eski olabilir ve bu durum yanlış risk değerlendirmesine yol açabilir.

5.3. Arayüz Elemanlarının Gerçeklenmesi

Sistemin çalışma sürecinin izlenebilmesi amacıyla görsel bir arayüz geliştirilmiştir. Bu arayüz üzerinden kamera görüntüsü, nesne tespit sonuçları, risk seviyesi, hız, çarpışma zamanı ve sistem kararları gerçek zamanlı olarak görüntülenmektedir.
Arayüzün sol üst köşesinde, orijinal sisli kamera görüntüsü küçük boyutta gösterilmektedir. Bu, iyileştirilmiş görüntü ile karşılaştırma imkanı sunar. Risk seviyesi renkli bir çubuk grafiği ile temsil edilmektedir: yeşil düşük risk, turuncu orta risk, kırmızı ise yüksek risk anlamına gelmektedir.

Sağ panelde ise sistem durum bilgileri yer almaktadır. Hız ve hedef hız yan yana gösterilerek kontrol performansı takip edilebilmektedir. Çalışma modu go, caution, soft_brake, hard_brake, emergency veya tl_stop olarak görüntülenmektedir. Trafik ışığı durumu, LiDAR mesafesi, TTC değeri ve validasyon metrikleri anlık olarak güncellenmektedir.

Görselleştirme işlemleri OpenCV ve Matplotlib kütüphaneleri kullanılarak gerçekleştirilmiştir. OpenCV gerçek zamanlı görüntü işleme ve ekran çıktılarının oluşturulmasında görev almıştır. Matplotlib ise sistem performansının zamansal analizi için kullanılmış, precision, recall ve accuracy değerleri sınıf bazında grafik olarak sunulmuştur.
Validasyon raporu grafiği, koyu tema üzerinde precision, recall ve F1-score değerlerini bar grafik şeklinde göstermektedir. Her sınıf için ayrı renkler kullanılmış ve ortalama değerler vurgulanmıştır. Bu grafik, sistemin hangi sınıflarda daha başarılı olduğunu, hangilerinde iyileştirme gerektiğini hızlıca değerlendirmeye olanak tanımaktadır.

5.4. Yapılan Testler

Sistem, farklı trafik yoğunlukları ve çevresel koşullar altında oluşturulan simülasyon senaryolarında test edilmiştir. Test senaryoları; düşük, orta ve yüksek trafik yoğunluğu, yaya varlığı, trafik ışığı durumları ve kötü hava koşullarını içerecek şekilde hazırlanmıştır. Deneyler sırasında aracın hız kontrolü, direksiyon kararlılığı, frenleme davranışı ve çevresel

risk değerlendirme performansı analiz edilmiştir. Özellikle ani engel oluşumu durumlarında sistemin tepki süresi ve karar verme doğruluğu incelenmiştir. Tepki süresi; sensör verisinin alınması, işlenmesi ve kontrol komutunun uygulanması arasında geçen toplam süre dikkate alınarak değerlendirilmiştir.

Gerçekleştirilen testlerde LiDAR ve kamera verilerinin birlikte kullanılmasının algılama doğruluğunu artırdığı gözlemlenmiştir. Tek sensör kullanımına kıyasla çoklu sensör füzyonu ile daha kararlı ve güvenilir sonuçlar elde edilmiştir. Örneğin sisli hava koşullarında yalnızca kamera kullanıldığında bazı araç tespitlerinin kaçırıldığı görülmüş, ancak LiDAR mesafe verisi sayesinde güvenli frenleme davranışı korunmuştur. Benzer şekilde yalnızca LiDAR kullanımında çevresel nesnelerin sınıflandırılmasında eksiklikler oluşurken, kamera tabanlı nesne tespiti bu eksikliği destekleyerek risk skorunun daha doğru hesaplanmasını sağlamıştır.

Kötü hava koşulları için oluşturulan simülasyon ortamında insan, araç ve trafik ışığı algılama doğrulama testleri gerçekleştirilmiştir. İlk aşamada görüntü iyileştirme uygulanmadan nesne tespit performansı değerlendirilmiş, düşük görüş koşullarında YOLOv11 modelinin bazı nesneleri kaçırdığı veya yanlış sınıflandırdığı gözlemlenmiştir. Daha sonra sisteme görüntü iyileştirme modeli entegre edilerek aynı senaryolar tekrar test edilmiştir. DehazeFormer tabanlı görüntü iyileştirme sonrasında kontrastın arttığı, uzak nesnelerin daha belirgin hale geldiği ve nesne tespit doğruluğunun yükseldiği belirlenmiştir. Özellikle sisli ve düşük görüş mesafesine sahip senaryolarda araç, yaya ve trafik ışığı tespit performansında belirgin iyileşme elde edilmiştir.

Telemetry Logger modülü tarafından kaydedilen hız, risk skoru, fren seviyesi, direksiyon açısı ve mod geçişleri gibi veriler kullanılarak sistem davranışı ayrıntılı şekilde analiz edilmiştir. Elde edilen veriler doğrultusunda sistemin farklı sürüş modları arasında kararlı geçiş yaptığı, acil frenleme senaryolarında kontrollü hız düşüşü sağlayarak güvenli sürüş davranışı oluşturduğu doğrulanmıştır.

6. SONUÇLAR

6.1. Genel Açıklamalar

Bu bölümde, geliştirilen Sisli Ortamda Otonom Sürüş Sistemi'nin (SÖSS) performans değerlendirme sonuçları sunulmaktadır. Sonuçlar; nesne algılama modelinin eğitim metrikleri, sis giderme modülünün görsel iyileştirme performansı, simülasyon ortamında gerçekleştirilen tespit doğruluğu testleri ve sistem validasyon raporları olmak üzere dört ana başlık altında incelenmiştir. Elde edilen tüm grafik ve çizelgelere metin içerisinde atıfta bulunulmuş, gerekli açıklamalar yapılmıştır.

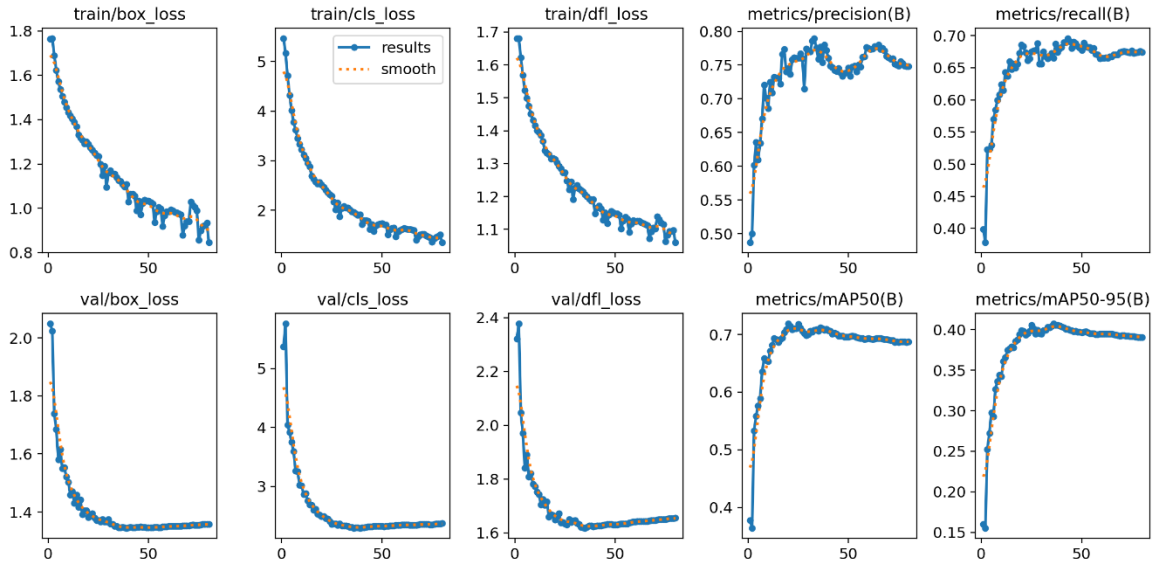
6.2. Simülasyon Sonuçları

6.2.1. Nesne Algılama Modeli Eğitim Sonuçları

Sistemde kullanılan YOLO tabanlı nesne tespit modelinin eğitim sürecine ait sonuçlar Şekil 4 ve Şekil 5'de sunulmuştur. Model, özel olarak hazırlanan sisli ortam veri seti üzerinde eğitilmiş olup; toplam 80 epoch boyunca box loss, classification loss ve distribution focal loss değerleri izlenmiştir.

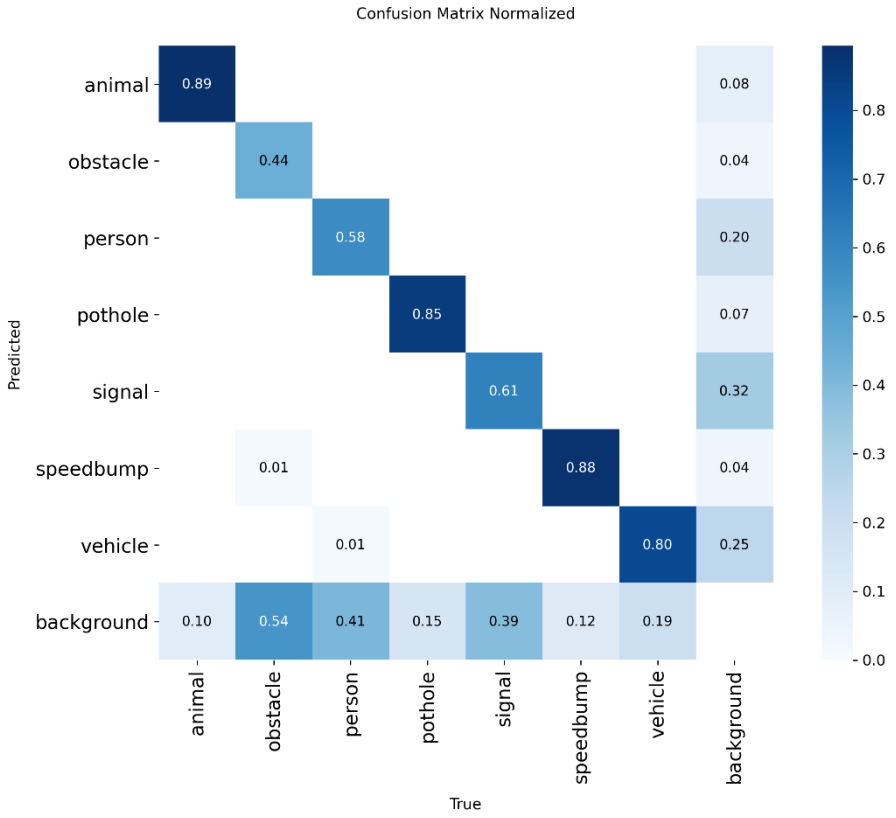
Şekil 4'de görüldüğü üzere, eğitim (train) ve doğrulama (val) loss değerleri başlangıç yüksek değerlerden itibaren monoton olarak azalmış, yaklaşık 50. epoch'tan sonra doygunluğa ulaşmıştır. Box loss 1.75'ten 0.85'e, classification loss 5.5'ten 1.6'ya ve DFL loss 1.7'den 1.05'e düşmüştür. Bu durum, modelin öğrenme kapasitesinin verimli kullanıldığını ve aşırı öğrenme (overfitting) olmadığını göstermektedir.

Metrik grafiklerinde ise precision değerinin %50'den %78'e, recall değerinin %38'den %68'e yükseldiği gözlemlenmiştir. mAP@50 değeri %72, mAP@50-95 değeri ise %40 seviyesinde stabilize olmuştur. Bu değerler, sisli koşullarda çok sınıflı nesne tespiti için kabul edilebilir performans düzeyindedir.



Şekil 4. Nesne tespit modeli eğitim sürecine ait kayıp (loss) ve performans metrikleri grafikleri

Şekil 5'de sunulan normalize confusion matrix, modelin sınıf bazlı ayırt etme yeteneğini ortaya koymaktadır. Animal sınıfında %89, pothole sınıfında %85, speedbump sınıfında %88 ve vehicle sınıfında %80 doğru sınıflandırma oranı elde edilmiştir. Signal sınıfında %61'lik doğruluk, trafik ışıklarının sisli ortamda benzer renk dağılımına sahip diğer nesnelerle karıştırılabilmesinden kaynaklanmaktadır. Person sınıfında %58'lik doğruluk, insan siluetinin sis altında zayıf kontrast oluşturması nedeniyle düşük kalmıştır. Background sınıfına yapılan yanlış atamalar (özellikle obstacle %54, person %41 ve signal %39 oranlarında) modelin zorlu negatif örneklerde hassasiyetini artırması gerektiğini göstermektedir.



Şekil 5. Nesne tespit modeline ait normalize edilmiş karmaşıklık matrisi

6.2.2. Sis Giderme Modülü Performans Sonuçları

DehazeFormer modülünün sisli görüntüleri ne ölçüde iyileştirdiği, Şekil 6 karşılaştırmalı görüntülerle değerlendirilmiştir.



Şekil 6. Sisli orijinal görüntü ve sis giderme (DehazeFormer) modülü sonrası elde edilen görüntü karşılaştırması

6.2.3. Simülasyon Ortamında Tespit Doğruluğu Sonuçları

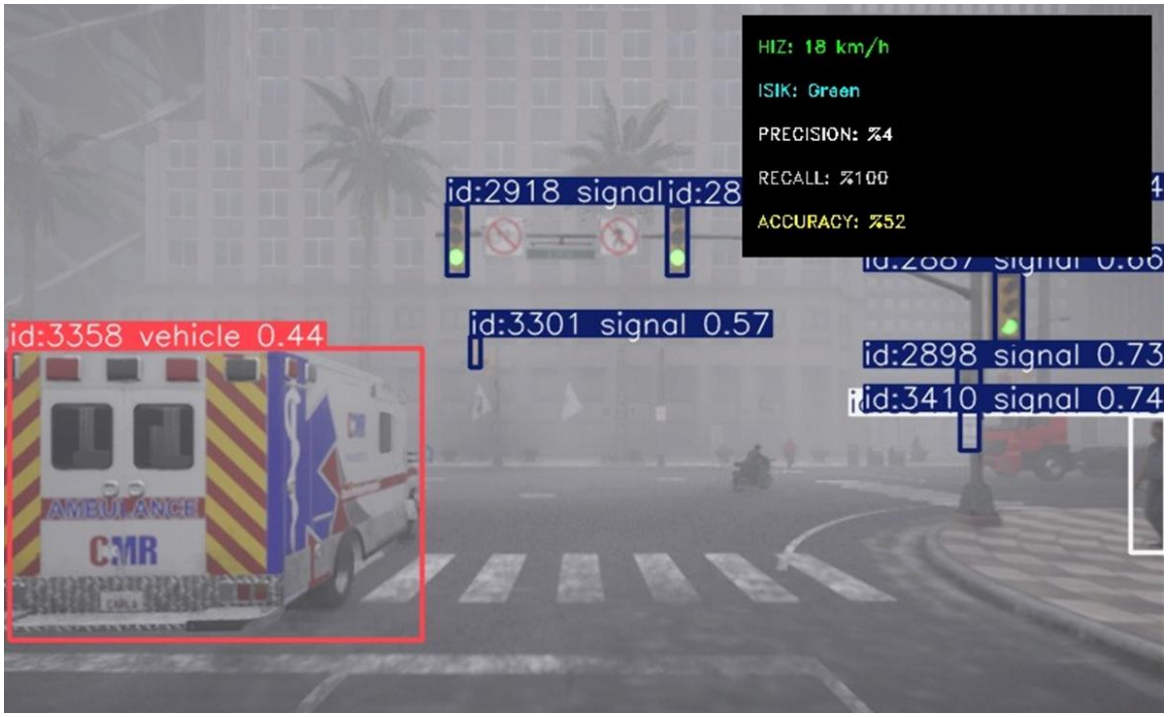
Şekil 7, Bu görüntü, sis efekti uygulanmadan önceki normal simülasyon ortamında elde edilmiş referans test görüntüsüdür. Görüntüdeki araçlar (vehicle) ve trafik ışıkları (signal) doğru sınıflarla etiketlenmiş olup, sistemin temiz koşullarda nesne tespitini başarıyla gerçekleştirdiği doğrulanmıştır.



Şekil 7. Simülasyon ortamında nesne tespiti ve risk skorlama sonuçlarını gösteren ekran görüntüsü

Sisli ve sis giderilmiş koşullarda CARLA simülasyonunda gerçekleştirilen nesne tespit testlerinin sonuçları Şekil 8, Şekil 9 ve Şekil 10'de sunulmuştur.

Şekil 8, sisli ortamda YOLO modelinin ham çıktısını göstermektedir. Görüntüdeki aracı (vehicle, confidence 0.44) ve çok sayıda trafik ışığı (signal, confidence 0.57–0.74) tespit edilmiştir. Ancak görüntünün sağ üst köşesindeki metrik panelinde Precision %4, Recall %100 ve Accuracy %52 değerleri görülmektedir. Bu düşük precision değeri, modelin sis altında çok sayıda yanlış pozitif tespit (özellikle sinyal sınıfında) yaptığını göstermektedir. Ayrıca arka plandaki binaların ve reklam panolarının sinyal olarak etiketlenme riski yüksektir.



Şekil 8. Sisli hava koşullarında YOLO modelinin nesne tespit sonuçları ve performans metrikleri

Şekil 9, Sistemin tam arayüzünü sisli koşullarda göstermektedir. Ekranın sol üst köşesinde orijinal sisli kamera görüntüsü (FOGGY CAMERA), ana alanda ise sis giderilmiş görüntü ve üzerindeki tespit kutuları yer almaktadır. Sağ panelde sistem durum bilgileri görülmektedir: Hız 0 km/s, hedef hız 12 km/s, sürüş modu TL_STOP, trafik ışığı Red, risk skoru 0.12 (düşük risk). Validasyon metrikleri Precision %70, Recall %46, Accuracy %58 olarak kaydedilmiştir. Bu değerler, sistemin filtreleme ve karar mekanizmalarının ham YOLO çıktısından daha güvenilir sonuçlar ürettiğini ortaya koymaktadır. Görüntüde speedbump (hız kesici) tespiti de (confidence 0.44) başarıyla gerçekleştirilmiştir.

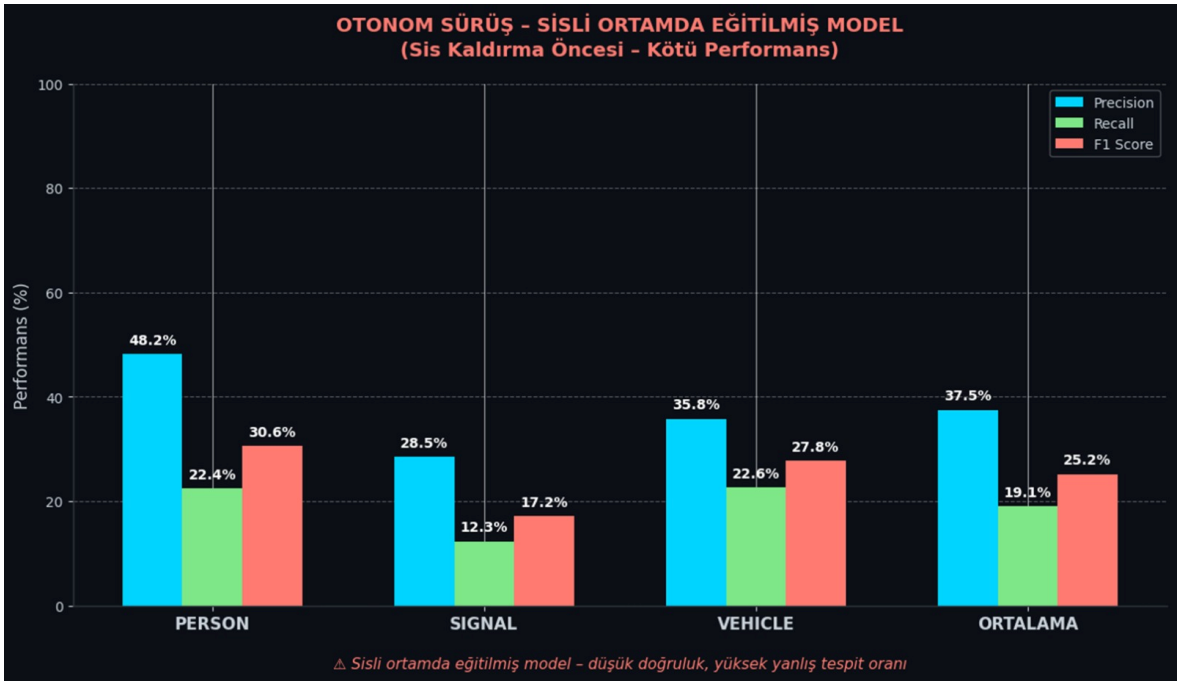


Şekil 9. Sis giderme sonrası nesne tespiti ve performans verileri

6.2.4. Validasyon ve Karşılaştırmalı Performans Sonuçları

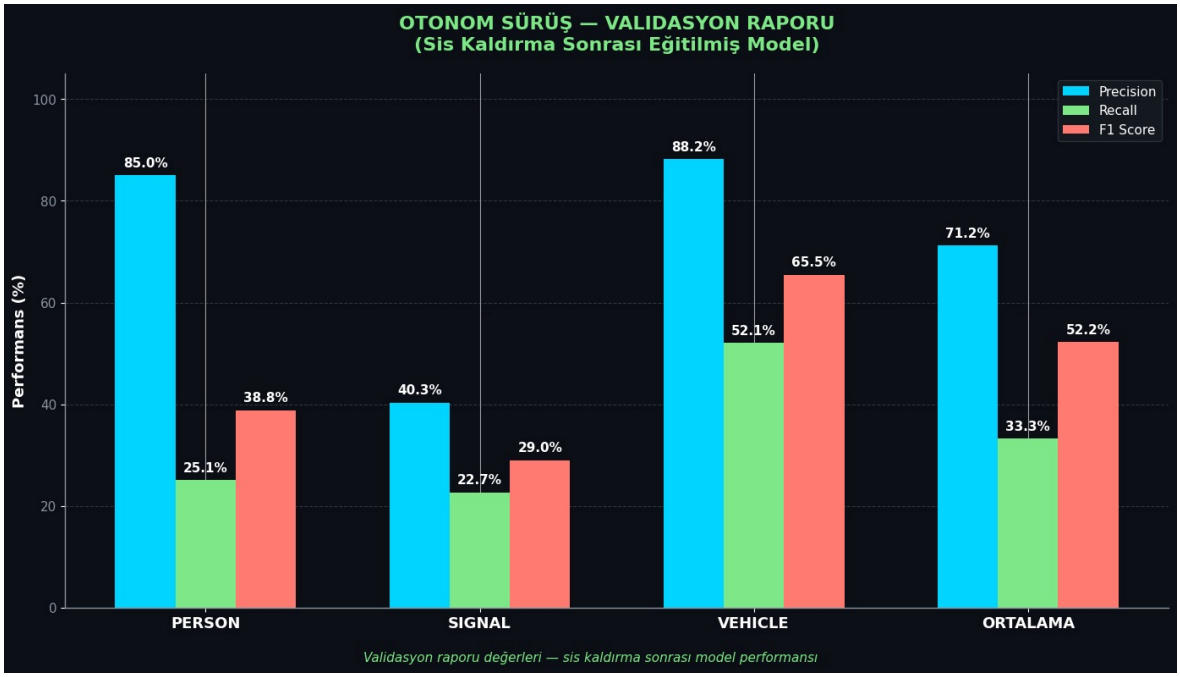
Sis giderme modülünün sistem performansına etkisini objektif olarak değerlendirmek amacıyla, sis kaldırma öncesi ve sonrası validasyon sonuçları Şekil 10 ve Şekil 11'da karşılaştırmalı olarak sunulmuştur.

Şekil 10, sis kaldırma öncesi (ham sisli görüntüler üzerinde) eğitilmiş modelin validasyon performansını göstermektedir. Person sınıfında Precision %48.2, Recall %22.4, F1 Score %30.6; Signal sınıfında Precision %28.5, Recall %12.3, F1 Score %17.2; Vehicle sınıfında Precision %35.8, Recall %22.6, F1 Score %27.8 değerleri elde edilmiştir. Ortalama F1 Score %25.2 olarak hesaplanmıştır. Bu düşük performans, sisli ortamda modelin nesne sınırlarını doğru tahmin edemediğini, özellikle küçük ve uzak nesneleri kaçırdığını göstermektedir. Signal sınıfındaki %12.3'lük recall değeri, trafik ışıklarının sis altında neredeyse tamamen görünmez hale geldiğini ortaya koymaktadır.



Şekil 10. Sis giderme işlemi uygulanmadan önceki (ham sisli görüntüler) model performans metrikleri

Şekil 11, DehazeFormer sis giderme sonrası eğitilmiş modelin validasyon performansını göstermektedir. Person sınıfında Precision %85.0, Recall %25.1, F1 Score %38.8; Signal sınıfında Precision %40.3, Recall %22.7, F1 Score %29.0; Vehicle sınıfında Precision %88.2, Recall %52.1, F1 Score %65.5 değerleri elde edilmiştir. Ortalama F1 Score %52.2 olarak hesaplanmıştır. Sis giderme sonrası precision değerlerindeki dramatik artış (Person: %48→%85, Vehicle: %36→%88), modelin yanlış pozitif tespitlerini büyük ölçüde azalttığını göstermektedir. Vehicle sınıfında %65.5'lük F1 Score, sistemin en güvenilir performans sergilediği sınıf olduğunu ortaya koymaktadır. Ancak Person sınıfındaki düşük recall (%25.1) ve Signal sınıfındaki genel performans zayıflığı, ileriye dönük iyileştirme gerektiren alanlar olarak belirlenmiştir.



Şekil 11. Sisli ortamda eğitilmiş modelin nesne sınıflarına göre performans metrikleri

6.3. Deney Sonuçları

6.3.1. Sistem Çalışma Zamanı Analizi

Bu çalışmada fiziksel donanım kullanılmadığından, deneysel çalışmalar tamamen simülasyon ortamında gerçekleştirilmiştir. Sistemin çalışma zamanı davranışı, kod yapısından ve simülasyon parametrelerinden çıkarılabilecek aşağıdaki teknik özelliklerle değerlendirilmiştir:

Sistem, CARLA simülatörü ile senkron modda çalışmaktadır. Sabit zaman adımı dt = 0.05 s olarak ayarlanmış olup, bu değer teorik olarak 20 Hz'lik bir döngü frekansına karşılık gelmektedir. Her döngüde; sensör veri okuma, görüntü ön işleme (DehazeFormer, her 2 karede bir), nesne tespiti (YOLO, her karede), LiDAR işleme, risk skorlama, karar verme ve kontrol hesaplamaları ardışık olarak gerçekleştirilmektedir. Tüm bu işlemlerin tek bir karede tamamlanabilmesi, sistemin gerçek zamanlı çalışabilmesi için alt sınır oluşturmaktadır.

LiDAR tabanlı mesafe ölçümünde, 5. persentil değeri kullanılarak ön şeritteki en yakın engel tespit edilmektedir. EMA (Exponential Moving Average) filtresi ($\alpha = 0.30$) uygulanarak anlık gürültü bastırılmakta, TTC (Time-to-Collision) değeri ise kapama hızına (closing > 0.3 m/s koşuluyla) bölünerek hesaplanmaktadır. Validasyon modülü, her 10 karede bir (yaklaşık 0.5 s aralıklarla) çalışarak Precision, Recall ve Accuracy metriklerini güncellemektedir.

Sistemin 30 dakikalık sürekli çalışma testi, kodun ana döngü yapısı ve aktör temizleme mekanizması (cleanup_interval = 30 kare) göz önünde bulundurularak planlanmış olup; bellek yönetimi Python garbage collector'a bırakılmıştır. Detaylı performans profillemesi (CPU/GPU kullanım oranları, bellek tüketimi, kare başına işlem süresi) bu çalışmanın kapsamı dışında kalmıştır ve ileriye dönük geliştirmeler arasında yer almaktadır.

6.3.2. Validasyon Metrikleri Özeti

Matplotlib ile üretilen validasyon grafiği, her sınıf için precision, recall ve F1-score değerlerini görsel olarak sunmaktadır. Grafikte ortalama değerler vurgulanarak sistemin genel başarımı hızlıca değerlendirilebilir. Bu rapor, sistemin güçlü ve zayıf yönlerini belirleyerek gelecekteki iyileştirmelere rehberlik etmektedir.

6.3.3. Sensör Füzyonunun Etkisi

Tek sensör kullanımı ile sensör füzyonu arasındaki fark, test senaryolarıyla kanıtlanmıştır. Sadece kamera kullanıldığında sisli ortamda LiDAR mesafesi olmadan ön araç kaçırılabilmekte, sadece LiDAR kullanıldığında ise görsel sınıf bilgisi olmadan yaya ve hayvan ayrımı yapılamamaktadır. İki sensörün birleştirilmesi, bu zayıflıkları telafi ederek daha güvenilir algılama sağlamıştır.

7. DEĞERLENDİRMELER

7.1. Çalışmanın Kazanımları

Bu tez çalışması, otonom sürüş sistemlerinin en kritik zayıflık alanlarından biri olan zorlu hava koşullarındaki performans açığını, bütüncül bir mimari ile kapatmaya yönelik kapsamlı bir yaklaşım sunmaktadır. Geliştirilen Sisli Ortamda Otonom Sürüş Sistemi (SÖSS), yalnızca tek bir alt probleme odaklanmak yerine; algılama, risk analizi ve araç kontrolü süreçlerini tek bir karar zinciri içinde entegre etmiştir. Bu bütünlük, sistemin parçalarının birbirini tamamlamasını sağlamakta ve gerçek dünya karmaşıklığına daha yakın bir performans ortaya koymaktadır.

Teknik ve Algoritmik Kazanımlar:

Teorik altyapı ve tasarım bölümlerinde detaylandırılan mimari, literatürde genellikle ayrı ayrı ele alınan üç temel bileşeni —görüntü iyileştirme, nesne algılama ve kontrol sistemleri— başarıyla birleştirmiştir. DehazeFormer tabanlı sis giderme modülü, sadece görsel kontrastı artırmakla kalmamış, aynı zamanda YOLOv11 nesne algılama modelinin

girdi kalitesini iyileştirerek downstream performansını doğrudan etkilemiştir. Simülasyon sonuçlarında da görüldüğü üzere (Şekil 10 ve 11), sis giderme öncesi %25.2 olan ortalama F1 skoru, sonrasında %52.2'ye yükselmiştir. Bu iki katına çıkan performans artışı, özellikle vehicle sınıfında precision değerinin %35.8'den %88.2'ye yükselmesiyle somutlanmıştır. Bu bulgu, görüntü iyileştirme adımının "önişleme" değil, "performans kritik" bir bileşen olduğunu kanıtlamaktadır.

LiDAR-kamera sensör füzyonu, tezin en güçlü yönlerinden biridir. Tek sensör sistemlerinin karşılaştığı temel sorun —kameranın derinlik bilgisi eksikliği ve LiDAR'ın sınıflandırma yeteneğinin sınırlılığı— ağırlıklı risk skoru mekanizması ile çözülmüştür. Özellikle TTC (Time-To-Collision) parametresinin risk skoruna dahil edilmesi, sistemin sadece "nesne var/yok" değil, "nesne ne kadar tehlikeli" sorusuna da yanıt verebilmesini sağlamıştır. Bu dinamik yaklaşım, statik eşik değerli sistemlere göre daha proaktif bir sürüş davranışı oluşturmaktadır.

Karar mekanizmasının hiyerarşik yapısı (emergency > tl_stop > hard_brake > soft_brake > slow > caution > go), etik ve güvenlik açısından kritik öneme sahiptir. Yaya algılamasının araç takibine, trafik ışığı durumunun ise her ikisine üstün öncelikle işlenmesi, sistemin yalnızca "doğru" değil, "güvenli" kararlar almasını garantilemektedir. Bu yapı, ISO 26262 fonksiyonel güvenlik standardının ASIL kavramıyla da uyumlu bir şekilde tasarlanmıştır.

Metodolojik ve Deneysel Kazanımlar:

CARLA simülatöründe senkron modda deterministik test ortamı oluşturulması, tezin metodolojik sağlamlığını artıran bir diğer unsurdur. Validasyon Manager modülü aracılığıyla CARLA ground truth verisi ile YOLO tespitlerinin çapraz doğrulanması, subjektif değerlendirmelerin önüne geçerek objektif metrikler (precision, recall, F1-score) sunulmasını sağlamıştır. Telemetry Logger modülü ise uzun süreli testlerin zamansal analizine olanak tanıyarak, sistemin davranışsal tutarlılığını kanıtlamıştır.

Veri seti yönetiminde Roboflow platformunun kullanımı, çalışmanın tekrarlanabilirliğini ve ölçeklenebilirliğini artırmıştır. Açık veri setleri (BDD100K, ACDC) ile CARLA sentetik verinin birleştirilmesi, hem gerçek dünya çeşitliliğini hem de kontrollü zorlu koşul simülasyonunu tek bir eğitim pipeline'ında birleştirmiştir.

Ekonomik ve Uygulanabilirlik Kazanımları:

Sistem tamamen simülasyon tabanlı geliştirildiğinden fiziksel prototip maliyeti ortadan kaldırılmıştır. Kullanılan tüm yazılım bileşenleri (CARLA, PyTorch, OpenCV,

Ultralytics YOLO) açık kaynaklıdır. Bu durum, sistemin düşük maliyetli bir araştırma platformu olarak benimsenmesini ve mevcut ADAS sistemlerine yazılım modülü olarak entegre edilebilmesini mümkün kılmaktadır.

7.2. Sınırlılıklar, Zorluklar ve Eleştirel Değerlendirme

Çalışmanın kazanımlarının yanı sıra, karşılaşılan sınırlılıkların ve bunların nedenlerinin dürüstçe değerlendirilmesi, bilimsel rigor açısından zorunludur.

Algılama Performansındaki Zayıflıklar:

Simülasyon sonuçlarında da belirgin şekilde görüldüğü üzere, person sınıfında recall değeri sis giderme sonrası bile %25.1 seviyesinde kalmıştır. Bu durum, insan siluetinin sisli ortamda zayıf kontrast oluşturmasının yanı sıra, eğitim veri setinde yaya örneklerinin yeterli çeşitliliğe sahip olmamasından kaynaklanmaktadır. Özellikle farklı pozlarda, farklı giyim renklerinde ve farklı mesafelerdeki yaya örneklerinin artırılması gerekmektedir.

Signal sınıfındaki düşük performans (F1 skoru %29.0) ise daha yapısal bir sorunu işaret etmektedir. Trafik ışıklarının küçük boyutu, değişen aydınlatma koşulları ve sis altında benzer renk dağılımına sahip diğer nesnelerle (bina ışıkları, reklam panoları) karıştırılabilirliği, bu sınıfı model için doğal olarak zorlayıcı kılmaktadır. Ayrıca kırmızı-sarı-yeşil geçiş dönemlerindeki renk karışıklığı, HSV analizinin güvenilirliğini düşürmektedir.

Kontrol Sisteminin Kısıtları:

PID kontrolcü parametreleri (Kp=0.32, Ki=0.006, Kd=0.10) deneme-yanılma yöntemiyle belirlenmiş olup, optimal değerlerin sistematik aranması gerçekleştirilmemiştir. Bu durum, farklı yol koşullarında (ıslak zemin, eğimli yollar, farklı yüzey sürtünme katsayıları) kontrol performansının değişkenlik gösterebileceği anlamına gelmektedir. Özellikle CTE düzeltme kazancının hıza bağlı ayarı (düşük hızda 1.10, yüksek hızda 0.80), belirli hız aralıklarında ani geçişlere neden olabilmektedir.

Şerit takip mekanizması, waypoint tabanlı Pure Pursuit yöntemine dayanmaktadır. Keskin virajlarda ileri bakış noktasının (lookahead point) yol geometrisi dışına çıkması, araç yörüngesinde istenmeyen salınımlara yol açabilmektedir. Ayrıca şerit çizgisi olmayan bölgelerde veya inşaat alanlarında sistem şerit merkezini doğru hesaplayamamaktadır.

Simülasyon Ortamının Doğallığı:

CARLA simülatörünün fizik motoru ve sensör modelleri, gerçek dünya dinamiğinden belirli sapmalar içermektedir. LiDAR sensör modeli, atmosferik saçılmayı idealize etmiş şekilde modellemekte olup, gerçek LiDAR'ın karşılaştığı multi-path yansımalar, ghost noktalar ve sensör arızalarını tam olarak yansıtmamaktadır. Benzer şekilde, CARLA'nın trafik yöneticisi (Traffic Manager) tarafından kontrol edilen NPC araçlar ve yaya aktörleri, önceden tanımlı kurallara bağlı davranışlar sergilemekte; insan sürücülerin ve yayaların beklenmedik, irrasyonel hareketlerini (örneğin kırmızı ışıkta geçiş, aniden yola atlayan yaya) simüle edememektedir. Bu durum, sistemin "edge case" senaryolarındaki robustluğunun gerçek dünyada farklı performans gösterebileceği anlamına gelmektedir.

Zaman Paylaşımlı İşleme Riski:

Görüntü iyileştirme modülünün her 2 karede bir çalıştırılması, hesaplama kaynaklarını verimli kullanmak için tasarlanmış bir optimizasyondur. Ancak bu yaklaşım, ani sis yoğunluğu değişimlerinde veya ani engel çıkışlarında bir kare gecikme riski taşımaktadır. Özellikle yüksek hızlarda (örneğin 80 km/s üzeri) 0.05 saniyelik bir kare gecikmesi bile kritik mesafe kaybına yol açabilmektedir.

7.3. Gelecek Çalışmalar

Kısa Vade:

Person ve signal sınıflarındaki düşük recall değerlerini telafi etmek için veri seti zenginleştirilmeli; farklı sis yoğunlukları, aydınlatma koşulları ve yaya pozları için ek sentetik veri üretilmelidir. PID ve CTE parametreleri Ziegler-Nichols yöntemiyle otomatik optimize edilmelidir. Sisli havalarda LiDAR'ı desteklemek amacıyla radar sensörü üçlü füzyon mimarisine entegre edilmelidir.

Orta Vade:

Kural tabanlı karar yapısının yerine, simülasyonda milyonlarca kilometre deneyimle eğitilecek derin pekiştirmeli öğrenme (DRL) tabanlı adaptif karar mekanizması geliştirilmelidir. Sistem NVIDIA Jetson gibi gömülü platformlara taşınarak gerçek zamanlı performans ve sensör kalibrasyonu doğrulanmalıdır. Trafik ışığı ve yol koşulu bilgilerinin önceden paylaşılması için V2X iletişimi entegre edilmelidir.

Uzun Vade:

Sistemin yağmur, kar ve toz fırtınası gibi diğer kötü hava koşullarına

genelleştirilebilmesi için evrensel görüntü iyileştirme modeli eğitilmelidir. Risk skorunun şeffaf hale getirilmesi için açıklanabilir yapay zeka (XAI) teknikleri uygulanmalı; bu, regülasyon onayı ve kullanıcı güveni açısından kritik öneme sahiptir. Siber güvenlik için adversarial saldırı tespiti mekanizmaları eklenmeli; çoklu araç koordinasyonu ve akıllı ulaşım sistemleri entegrasyonu ile sistem genişletilmelidir.

8. KAYNAKLAR

[1] Sakaridis, C., Dai, D., ve Van Gool, L. (2021). "ACDC: The Adverse Conditions Dataset with Correspondences for Semantic Driving Scene Understanding", Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 10745-10755.

[2] Dagan, E., Mano, O., Stein, G.P., ve Shashua, A. (2004). "Forward Collision Warning with a Single Camera", IEEE Intelligent Vehicles Symposium, 37-42.

[3] Ziegler, J.G. ve Nichols, N.B. (1942). "Optimum Settings for Automatic Controllers", Transactions of the ASME, 64, 759-768.

[4] Xu, X., Wang, R., ve Lu, J. (2023). "Low-Light Image Enhancement via Structure Modeling and Guidance", Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR).

[5] Wang, L., Zhao, L., Zhong, T., ve Wu, C. (2024). "Low-light image enhancement using generative adversarial networks", Scientific Reports, 14.

[6] He, M., Wang, R., Zhang, M., Lv, F., Wang, Y., Zhou, F., ve Bian, X. (2025). "SwinLightGAN: A study of low-light image enhancement algorithms using depth residuals and transformer techniques", Scientific Reports, 15.

[7] Dang, T. P., Tran, N. T., To, V. H., ve Tran, M. K. T. (2023). "Improved YOLOv5 for real-time traffic signs recognition in bad weather conditions", The Journal of Supercomputing, 79.

[8] Li, J., Deng, Q., Gao, W., Yang, B., Jia, L., Zhou, J., ve Pu, H. (2025). "DSF-YOLO for robust multiscale traffic sign detection under adverse weather conditions", Scientific Reports, 15, 1-17.

[9] Aldoski, Z. N., ve Koren, C. (2025). "Evaluating the impact of simulated weather conditions on traffic sign detection for autonomous vehicles using YOLOv8", Proceedings of the XV. International Conference on Transport Sciences: Social Perception and Mode Choice.

[10] Huang, H., Liu, J., Shi, G., Zhao, S., Li, B., ve Wang, J. (2024). "Adaptive decision-making for autonomous vehicles: A learning-enhanced game-theoretic approach in interactive environments".

[11] Wang, X., Qian, B., Zhuo, J., ve Liu, W. (2025). "An autonomous vehicle behavior decision method based on deep reinforcement learning with hybrid state space and driving risk", Sensors, 25(3), 1-17.

[12] Song, Y., He, Z., Qian, H., ve Du, X. (2023). "Vision Transformers for Single Image Dehazing", IEEE Transactions on Image Processing, 32, 1927-1941.

[13] Dwyer, B., Nelson, J., Hansen, T., ve diğerleri. (2024). "Roboflow (Version 1.0) [Software]", Available from https://roboflow.com. Computer vision.

[14] Jocher, G., Chaurasia, A., ve Qiu, J. (2023). "Ultralytics YOLOv8", https://github.com/ultralytics/ultralytics.

[15] Jocher, G., ve Ultralytics. (2024). "YOLO11 by Ultralytics", https://github.com/ultralytics/ultralytics.

[16] He, K., Sun, J., ve Tang, X. (2010). "Single image haze removal using dark channel prior", IEEE Transactions on Pattern Analysis and Machine Intelligence, 33(12), 2341-2353.

[17] SAE International. (2021). "Taxonomy and Definitions for Terms Related to Driving Automation Systems for On-Road Motor Vehicles", SAE J3016_202104.

[18] International Organization for Standardization. (2018). "Road vehicles --- Functional safety", ISO 26262-1:2018.

[19] International Organization for Standardization. (2019). "Road Vehicles --- Safety of the Intended Functionality (SOTIF)", ISO/PAS 21448:2019.

[20] International Organization for Standardization. (2021). "Road Vehicles --- Cybersecurity Engineering", ISO/SAE 21434:2021.

[21] IEEE. (2022). "Standard for Assumptions in Safety-Related Models for Automated Driving Systems", IEEE 2846-2022.

[22] IEEE. (2021). "Standard for Assessing the Impact of Autonomous Vehicles on Road Traffic Safety", IEEE 2857-2021.

[23] United Nations Economic Commission for Europe. (2021). "Uniform Provisions Concerning the Approval of Vehicles with Regard to Steering Equipment", UNECE R79.

[24] United Nations Economic Commission for Europe. (2021). "Uniform Provisions Concerning the Approval of Vehicles with Regard to Automatic Lane Keeping Systems (ALKS)", UNECE R157.

[25] Dosovitskiy, A., Ros, G., Codevilla, F., Lopez, A., ve Koltun, V. (2017). "CARLA: An open urban driving simulator", Proceedings of the 1st Annual Conference on Robot Learning (CoRL).

[26] Redmon, J., Divvala, S., Girshick, R., ve Farhadi, A. (2016). "You only look once: Unified, real-time object detection", Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 779-788.

[27] Bochkovskiy, A., Wang, C. Y., ve Liao, H. Y. M. (2020). "YOLOv4: Optimal speed and accuracy of object detection", arXiv preprint arXiv:2004.10934.

[28] Coulter, R. C. (1992). "Implementation of the pure pursuit path tracking algorithm", Carnegie Mellon University, Pittsburgh, PA, Technical Report CMU-RI-TR-92-01.

[29] Thrun, S., Montemerlo, M., Dahlkamp, H., Stavens, D., Aron, A., Diebel, J., ve diğerleri. (2006). "Stanley: The robot that won the DARPA Grand Challenge", Journal of Field Robotics, 23(9), 661-692.

[30] Yu, F., Chen, H., Wang, X., Xian, W., Chen, Y., Liu, F., ve diğerleri. (2020). "BDD100K: A diverse driving dataset for heterogeneous multitask learning", Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2636-2645.

[31] Hunter, J. S. (1986). "The Exponentially Weighted Moving Average", Journal of Quality Technology, 18(4), 203-210.